



Solution – Exam Module 2 CHALLENGE

Nhóm ra đề AIO

Mục lục

I.	AIO25M02Q01	2
II.	AIO26M02Q02	8
III.	AIO26M02Q03	13
IV.	AIO26M02Q04	18
V.	AIO26M02Q05	23
VI.	AIO26M02Q06	28
VII.	AIO26M02Q07	32
VIII.	AIO26M02Q08	35
IX.	AIO26M02Q10	40
X.	AIO26M02Q11	44

I. AIO25M02Q01

Tại *NASA Ames Research Center*, các nhà nghiên cứu thuộc lĩnh vực *Prognostics and Health Management* nghiên cứu các phương pháp dự đoán tình trạng sức khỏe và thời gian sử dụng còn lại của pin lithium-ion. Một trong những mục tiêu của bài toán này là dự đoán liệu pin còn đủ năng lượng để hoàn thành nhiệm vụ hay không. Dựa trên kết quả dự đoán, hệ thống có thể quyết định tiếp tục sử dụng pin, thay pin hoặc điều chỉnh phạm vi hoạt động, từ đó hạn chế nguy cơ thiết bị hết năng lượng khi đang vận hành.

NASA Ames đã công bố bộ dữ liệu *Li-ion Battery Aging Datasets*, được thu thập từ một hệ thống thử nghiệm pin tại *Prognostics Center of Excellence*. Trong thí nghiệm, các pin lithium-ion loại 18650 được vận hành qua nhiều chu kỳ sạc, xả và đo trở kháng điện hóa. Trong mỗi chu kỳ xả, hệ thống ghi lại điện áp, dòng điện, nhiệt độ, thời gian và dung lượng còn lại của pin.

Gọi Q_k là dung lượng đo được tại chu kỳ xả thứ k và $Q_{\text{rated}} = 2$ Ah là dung lượng định mức. Trong câu hỏi này, *capacity-based State of Health* được định nghĩa bởi:

$$\text{SOH}_Q(k) = \frac{Q_k}{Q_{\text{rated}}} = \frac{Q_k}{2}.$$

Pin được xem là đạt trạng thái *End-of-Life* (EOL) khi dung lượng suy giảm ít nhất 30% so với dung lượng định mức, tương đương với:

$$\text{SOH}_Q(k) \leq 0.7 \iff Q_k \leq 1.4 \text{ Ah}.$$

Bảng 1 trình bày năm chu kỳ xả được chọn từ pin B0005 trong dữ liệu NASA. Các giá trị đã được làm tròn từ dữ liệu gốc. Cột “Thời điểm điện áp dưới 3 V” cho biết số giây tính từ đầu chu kỳ xả đến khi điện áp đo được lần đầu tiên giảm xuống dưới 3 V.

Bảng 1: **Các chu kỳ xả được chọn từ pin B0005.** Dung lượng còn lại, nhiệt độ cực đại và thời điểm điện áp lần đầu giảm xuống dưới 3 V được tổng hợp từ *Li-ion Battery Aging Datasets* của NASA Ames. Các giá trị được làm tròn từ dữ liệu gốc. Pin được xem là đạt EOL khi dung lượng không vượt quá 1.4 Ah.

Chỉ số chu kỳ xả	Dung lượng còn lại (Ah)	Nhiệt độ cực đại (°C)	Thời điểm điện áp dưới 3 V (giây)
0	1.8565	38.98	3287.97
40	1.7679	38.75	3129.77
80	1.5598	39.47	2718.64
120	1.4383	41.36	2492.70
150	1.3601	41.05	2351.95

Trong dữ liệu huấn luyện, dung lượng đo được sau khi hoàn thành chu kỳ xả được sử dụng để xác định pin đã đạt EOL hay chưa. Tuy nhiên, trước một nhiệm vụ UAV, không thể thực hiện trước một chu kỳ xả hoàn chỉnh chỉ để xác định chính xác dung lượng cuối chu kỳ. Vì vậy, nhóm nghiên cứu xây dựng một mô hình Machine Learning sử dụng lịch sử hoạt động và các tín hiệu cảm biến hiện có để dự đoán liệu pin có chuyển sang trạng thái EOL sau nhiệm vụ tiếp theo hay không.

Với mỗi lượt đánh giá, mô hình trả về một *risk score* trong khoảng từ 0 đến 1. Nếu risk score lớn hơn classification threshold, hệ thống phát cảnh báo và yêu cầu kỹ thuật viên kiểm tra pin thủ công.

Trong phần còn lại của câu hỏi:

- F là sự kiện pin đạt trạng thái EOL sau nhiệm vụ tiếp theo.
- $+$ là sự kiện mô hình phát cảnh báo.
- $-$ là sự kiện mô hình không phát cảnh báo.

Do các trường hợp EOL tương đối hiếm, nhóm nghiên cứu xây dựng tập validation cân bằng, gồm 50% mẫu thuộc lớp F và 50% mẫu thuộc lớp $\bar{F}$. Trong môi trường triển khai, xác suất một lượt đánh giá gập pin sẽ đạt EOL sau nhiệm vụ tiếp theo được ước lượng là $P(F) = 0.005$, Do đó: $P(\bar{F}) = 0.995$. Nhóm nghiên cứu đang cân nhắc hai classification threshold là τ_1 và τ_2 . Kết quả đánh giá được trình bày trong Bảng 2.

Bảng 2: Hiệu năng của mô hình tại hai classification threshold. Sensitivity và specificity được đo trên tập validation cân bằng và được giả sử không thay đổi trong kịch bản triển khai của câu hỏi.

Threshold	Sensitivity $P(+ F)$	Specificity $P(- \bar{F})$
τ_1	96%	90%
τ_2	88%	99%

Sensitivity $P(+ | F)$ là xác suất mô hình phát cảnh báo khi pin thật sự đạt EOL sau nhiệm vụ. Specificity $P(- | \bar{F})$ là xác suất mô hình không cảnh báo khi pin vẫn chưa đạt EOL.

Trong một đợt mô phỏng gồm 10 000 lượt đánh giá pin, nhóm vận hành sử dụng các giả định sau:

1. Bỏ sót một pin sẽ đạt EOL, tức một false negative, gây thiệt hại kỳ vọng là 500 đơn vị chi phí.
2. Kiểm tra không cần thiết một pin chưa đạt EOL, tức một false positive, gây thiệt hại là 3 đơn vị chi phí.
3. Đội kỹ thuật chỉ có thể xử lý trung bình tối đa 150 cảnh báo trên 10 000 lượt đánh giá.
4. Một threshold được xem là khả thi nếu số cảnh báo kỳ vọng không vượt quá 150.
5. Sensitivity và specificity trong Bảng 2 được giả sử không thay đổi khi mô hình được triển khai.
6. Vì đang xét các đại lượng kỳ vọng, số trường hợp tính được có thể không phải là số nguyên.

Câu hỏi: Phương án nào dưới đây đồng thời xác định đúng trạng thái EOL của các chu kỳ trong Bảng 1 và lựa chọn đúng classification threshold cho kịch bản triển khai?

- A. Chu kỳ 150 là chu kỳ duy nhất trong bảng đã đạt EOL. Nên chọn τ_1 vì trong 50 pin thuộc lớp F , threshold này tạo ra 48 true positive, 2 false negative và 5 false positive, tương ứng 53 cảnh báo và tổng chi phí kỳ vọng 1015 đơn vị. Vì vậy, τ_1 vừa có chi phí thấp vừa đáp ứng giới hạn xử lý.

- B.** Chu kỳ 150 là chu kỳ duy nhất trong bảng đã đạt EOL. Nên chọn τ_2 vì xác suất pin thật sự đạt EOL sau khi nhận cảnh báo xấp xỉ 30.7%. Threshold này tạo ra khoảng 143.5 cảnh báo và có tổng chi phí kỳ vọng khoảng 3298.5 đơn vị, thấp hơn τ_1 , đồng thời không vượt quá khả năng xử lý của đội kỹ thuật.
- C.** Chu kỳ 150 là chu kỳ duy nhất trong bảng đã đạt EOL. Nên chọn τ_2 vì xác suất pin thật sự đạt EOL sau cảnh báo được tính bởi $0.88/(0.88 + 0.01) \approx 98.9\%$. Threshold này tạo ra khoảng 143.5 cảnh báo và có tổng chi phí kỳ vọng khoảng 3298.5 đơn vị, nên đáp ứng các yêu cầu triển khai.
- D.** Cả chu kỳ 120 và chu kỳ 150 đều được xem là đã đạt EOL vì dung lượng 1.4383 Ah của chu kỳ 120 có thể làm tròn thành 1.4 Ah. Nên chọn τ_2 vì xác suất sau cảnh báo xấp xỉ 30.7%, số cảnh báo kỳ vọng là 143.5 và tổng chi phí kỳ vọng là 3298.5 đơn vị.

Đáp án đúng: B.

Giải thích

Dung lượng định mức ban đầu là 2 Ah. Khi dung lượng suy giảm 30%, ngưỡng EOL tương ứng là:

$$Q_{\text{EOL}} = Q_{\text{rated}} \times (1 - 0.30) = 2 \times 0.70 = 1.4 \text{ Ah.}$$

Do đó, pin đạt trạng thái EOL khi:

$$Q_k \leq 1.4 \text{ Ah.}$$

Trong Bảng 1, chu kỳ 150 có dung lượng 1.3601 Ah nên đã đạt EOL. Chu kỳ 120 có dung lượng 1.4383 Ah nên chưa đạt EOL. Vì vậy, chu kỳ 150 là chu kỳ duy nhất trong bảng đã đạt EOL.

Trong 10 000 lượt đánh giá, số pin dự kiến thuộc lớp F là:

$$N_F = 10\,000 \times 0.005 = 50.$$

Số pin dự kiến thuộc lớp $\bar{F}$ là:

$$N_{\bar{F}} = 10\,000 - 50 = 9950.$$

Tính toán với Threshold τ_1

Threshold τ_1 có sensitivity 96% và specificity 90%. Do đó:

$$TP_1 = N_F \times 0.96 = 50 \times 0.96 = 48,$$

$$FN_1 = N_F \times (1 - 0.96) = 50 \times 0.04 = 2,$$

$$FP_1 = N_{\bar{F}} \times (1 - 0.90) = 9950 \times 0.10 = 995.$$

Số cảnh báo kỳ vọng là:

$$N_{+,1} = TP_1 + FP_1 = 48 + 995 = 1043.$$

Theo định lý Bayes, xác suất pin thật sự đạt EOL sau khi mô hình phát cảnh báo là:

$$\begin{aligned} P_1(F | +) &= \frac{P(+ | F)P(F)}{P(+ | F)P(F) + P(+ | \bar{F})P(\bar{F})} \\ &= \frac{0.96 \times 0.005}{0.96 \times 0.005 + 0.10 \times 0.995} \\ &= \frac{48}{48 + 995} \approx 0.046 = 4.6\%. \end{aligned}$$

Gọi $\mathcal{L}_1$ là tổng chi phí kỳ vọng của Threshold τ_1 . Khi đó:

$$\begin{aligned}\mathcal{L}_1 &= 500 \times FN_1 + 3 \times FP_1 \\ &= 500 \times 2 + 3 \times 995 \\ &= 3985.\end{aligned}$$

Threshold τ_1 tạo ra 1043 cảnh báo, vượt quá giới hạn 150 cảnh báo.

Tính toán với Threshold τ_2

Threshold τ_2 có sensitivity 88% và specificity 99%. Do đó:

$$TP_2 = N_F \times 0.88 = 50 \times 0.88 = 44,$$

$$FN_2 = N_F \times (1 - 0.88) = 50 \times 0.12 = 6,$$

$$FP_2 = N_{\bar{F}} \times (1 - 0.99) = 9950 \times 0.01 = 99.5.$$

Số cảnh báo kỳ vọng là:

$$N_{+,2} = TP_2 + FP_2 = 44 + 99.5 = 143.5.$$

Xác suất pin thật sự đạt EOL sau khi mô hình phát cảnh báo là:

$$\begin{aligned}P_2(F | +) &= \frac{P(+ | F)P(F)}{P(+ | F)P(F) + P(+ | \bar{F})P(\bar{F})} \\ &= \frac{0.88 \times 0.005}{0.88 \times 0.005 + 0.01 \times 0.995} \\ &= \frac{44}{44 + 99.5} \approx 0.3066 = 30.7\%.\end{aligned}$$

Gọi $\mathcal{L}_2$ là tổng chi phí kỳ vọng của Threshold τ_2 . Khi đó:

$$\begin{aligned}\mathcal{L}_2 &= 500 \times FN_2 + 3 \times FP_2 \\ &= 500 \times 6 + 3 \times 99.5 \\ &= 3298.5.\end{aligned}$$

Threshold τ_2 tạo ra khoảng 143.5 cảnh báo, không vượt quá giới hạn 150 cảnh báo.

Bảng 3: Kết quả kỳ vọng của hai classification threshold. Bảng tổng hợp số true positive, false negative, false positive, tổng số cảnh báo, xác suất sau cảnh báo và chi phí kỳ vọng trên 10000 lượt đánh giá pin.

Threshold	TP	FN	FP	Cảnh báo	$P(F +)$	Chi phí
τ_1	48	2	995	1043	4.6%	3985
τ_2	44	6	99.5	143.5	30.7%	3298.5

So với τ_1 , Threshold τ_2 có chi phí kỳ vọng thấp hơn:

$$\mathcal{L}_2 = 3298.5 < 3985 = \mathcal{L}_1.$$

Threshold τ_2 cũng đáp ứng giới hạn vận hành:

$$N_{+,2} = 143.5 < 150.$$

Vì vậy, Threshold τ_2 là lựa chọn phù hợp nhất.

Vì sao các đáp án khác sai?

- **A sai** vì false positive rate phải được áp dụng cho 9950 pin thuộc lớp $\bar{F}$, không phải 50 pin thuộc lớp F . Số false positive đúng là:

$$FP_1 = 9950 \times 0.10 = 995,$$

không phải 5. Vì vậy, Threshold τ_1 tạo ra 1043 cảnh báo và có tổng chi phí kỳ vọng 3985 đơn vị.

- **C sai** vì công thức $0.88/(0.88 + 0.01)$ đã bỏ qua xác suất tiên nghiệm $P(F)$. Công thức đúng phải sử dụng đầy đủ định lý Bayes, cho kết quả:

$$P_2(F | +) \approx 30.7\%.$$

- **D sai** vì phải so sánh giá trị dung lượng được cung cấp trực tiếp với ngưỡng EOL. Chu kỳ 120 có:

$$Q_{120} = 1.4383 > 1.4 \text{ Ah},$$


nên chưa đạt EOL.

Nguồn dữ liệu: B. Saha và K. Goebel, *Battery Data Set*, NASA Ames Prognostics Data Repository, NASA Ames Research Center, [NASA Open Data Portal](#).

II. AIO26M02Q02

Một robot thám hiểm tự hành có tên *AIOBOT-26* đang khảo sát một hang dung nham. Trên đường quay về trạm sạc, robot gặp một đoạn nền đá hẹp nằm phía trên một hốc rỗng. Do khu vực thiếu ánh sáng và bề mặt bị phủ bởi một lớp bụi dày, camera không thể xác định trực tiếp liệu nền đá có đủ khả năng chịu khối lượng của robot hay không.

Robot phải tự động quyết định nên đi qua đoạn nền đá, đi theo một tuyến đường vòng an toàn hơn hoặc dành thêm thời gian và năng lượng để thực hiện một phép đo bổ sung. Quyết định này phải dựa trên xác suất nền đá bị yếu, độ tin cậy của các cảm biến và hậu quả có thể xảy ra với từng lựa chọn.



Hình 1: Các lựa chọn của robot sau cảnh báo radar A^+ . Robot có thể đi qua, thực hiện phép đo bổ sung hoặc đi đường vòng. Phép đo bổ sung có thể trả về kết quả B^+ hoặc B^- .

Gọi H là sự kiện:

“Đoạn nền đá có cấu trúc yếu và không thể chịu được khối lượng của robot.”

Dựa trên bản đồ địa chất của khu vực, xác suất tiên nghiệm được ước lượng là:

$$P(H) = 0.04, \quad P(\overline{H}) = 0.96.$$

Trước khi ra quyết định, robot sử dụng một cảm biến radar xuyên đất. Ký hiệu A^+ là sự kiện radar phát hiện dấu hiệu bất thường cho thấy bên dưới nền đá tồn tại hốc rỗng khiến nền đá không thể chịu được khối lượng của robot. Cảm biến có các đặc trưng sau:

$$P(A^+ | H) = 0.90. \quad P(A^- | \bar{H}) = 0.85.$$

Do đó:

$$P(A^+ | \bar{H}) = 1 - 0.85 = 0.15.$$

Trong tình huống hiện tại, robot đã nhận được cảnh báo A^+ .

Để so sánh các lựa chọn, nhóm thiết kế sử dụng một thang điểm nhiệm vụ. Điểm này tổng hợp mức độ hoàn thành nhiệm vụ, lượng năng lượng tiêu thụ, dữ liệu khoa học thu được và nguy cơ mất robot. Sau khi nhận cảnh báo A^+ , robot có thể chọn một trong ba phương án sau:

1. Đi qua ngay.

Nếu nền đá ổn định, robot hoàn thành nhiệm vụ đúng thời hạn và nhận +80 điểm. Nếu nền đá yếu, robot có thể rơi xuống hố và nhiệm vụ thất bại, tương ứng với -600 điểm.

2. Đi đường vòng.

Tuyến đường vòng được xem là an toàn, nhưng robot tiêu tốn thêm năng lượng và thu thập được ít dữ liệu khoa học hơn. Phương án này mang lại +20 điểm, không phụ thuộc vào trạng thái của nền đá.

3. Thực hiện phép đo bổ sung.

Robot triển khai một đầu dò rung để kiểm tra nền đá. Phép đo tiêu tốn thời gian và năng lượng, tương ứng với -6 điểm. Sau khi nhận kết quả từ đầu dò, robot được phép lựa chọn lại giữa đi qua và đi đường vòng. Tổng điểm của phương án này bằng -6 cộng với điểm của hành động được chọn sau phép đo.

Ký hiệu B^+ là sự kiện đầu dò báo nền đá yếu và B^- là sự kiện đầu dò báo nền đá ổn định. Đầu dò có:

$$P(B^+ | H) = 0.95, \quad P(B^- | \bar{H}) = 0.92.$$

Tương đương:

$$P(B^- | H) = 0.05, \quad P(B^+ | \bar{H}) = 0.08.$$

Giả sử sai số của radar và đầu dò độc lập có điều kiện khi đã biết trạng thái thật của nền đá. Nói cách khác, sau khi đã biết H hoặc $\bar{H}$, kết quả của radar không làm thay đổi xác suất đầu dò trả về B^+ hay B^- .

Robot cần lựa chọn một quy tắc ra quyết định sao cho tổng điểm kỳ vọng, tính từ thời điểm đã quan sát A^+ , là lớn nhất.

Câu hỏi: Phương án nào dưới đây đưa ra quy tắc ra quyết định chính xác nhất cho robot?

- A.** Robot nên đi đường vòng ngay. Từ cảnh báo radar, xác suất nền đá yếu là $0.90/(0.90 + 0.15) \approx 85.7\%$, nên điểm kỳ vọng của việc đi qua xấp xỉ -502.9. Ngay cả khi đầu dò trả về B^- , xác suất nền đá yếu vẫn xấp xỉ 24.6%, nên robot vẫn phải đi đường vòng. Vì vậy, phép đo bổ sung chỉ làm giảm điểm từ 20 xuống 14.

- B. Robot nên thực hiện phép đo bổ sung. Sau cảnh báo radar, xác suất nền đá yếu là 20%. Nếu đầu dò trả về B^+ , xác suất này tăng lên khoảng 74.8% và robot nên đi đường vòng. Nếu đầu dò trả về B^- , xác suất giảm xuống khoảng 1.34% và robot nên đi qua. Tổng điểm kỳ vọng của quy tắc này xấp xỉ 51.96, lớn hơn điểm kỳ vọng của hai lựa chọn còn lại.
- C. Robot nên đi đường vòng ngay. Sau cảnh báo radar, xác suất nền đá yếu là 20%, nên điểm kỳ vọng của việc đi qua là -56 , thấp hơn 20 điểm của đường vòng. Vì phép đo bổ sung không làm thay đổi trạng thái vật lý thật sự của nền đá, điểm kỳ vọng của việc đi qua vẫn là -56 sau phép đo. Phép đo do đó chỉ làm giảm điểm của phương án đường vòng từ 20 xuống 14.
- D. Robot nên đi đường vòng ngay. Sau cảnh báo radar, xác suất nền đá yếu là 20% và xác suất đầu dò trả về B^+ là 25.4%. Khi nhận B^- , xác suất nền đá yếu bằng $1 - 0.92 = 8\%$, nên điểm kỳ vọng của việc đi qua là 25.6. Tổng điểm kỳ vọng của việc đo rồi lựa chọn hành động xấp xỉ 18.2, vẫn thấp hơn 20 điểm của đường vòng.

Đáp án đúng: B.

Giải thích

Sau khi radar phát cảnh báo, áp dụng định lý Bayes:

$$\begin{aligned} P(H | A^+) &= \frac{P(A^+ | H)P(H)}{P(A^+ | H)P(H) + P(A^+ | \bar{H})P(\bar{H})} \\ &= \frac{0.90(0.04)}{0.90(0.04) + 0.15(0.96)} = 0.20. \end{aligned}$$

Gọi q là xác suất hiện tại nền đá yếu. Điểm kỳ vọng của việc đi qua là:

$$V_{\text{cross}}(q) = 80(1 - q) - 600q = 80 - 680q.$$

Robot nên đi qua thay vì đi đường vòng khi:

$$80 - 680q > 20 \iff q < \frac{60}{680} \approx 0.0882.$$

Với $q = 0.20$:

$$V_{\text{cross}}(0.20) = 80(0.80) - 600(0.20) = -56.$$

Nếu không thực hiện phép đo bổ sung, robot nên đi đường vòng và nhận 20 điểm.

Xác suất đầu dò báo nền đá yếu sau khi radar đã phát cảnh báo là:

$$\begin{aligned} P(B^+ | A^+) &= P(B^+ | H)P(H | A^+) \\ &\quad + P(B^+ | \bar{H})P(\bar{H} | A^+) \\ &= 0.95(0.20) + 0.08(0.80) \\ &= 0.254. \end{aligned}$$

Do đó:

$$P(B^- | A^+) = 1 - 0.254 = 0.746.$$

Nếu đầu dò trả về B^+ , xác suất nền đá yếu trở thành:

$$\begin{aligned} P(H | A^+, B^+) &= \frac{0.95(0.20)}{0.95(0.20) + 0.08(0.80)} \\ &\approx 0.748. \end{aligned}$$

Vì $0.748 > 0.0882$, robot nên đi đường vòng.

Nếu đầu dò trả về B^- , xác suất nền đá yếu trở thành:

$$\begin{aligned} P(H | A^+, B^-) &= \frac{0.05(0.20)}{0.05(0.20) + 0.92(0.80)} \\ &\approx 0.0134. \end{aligned}$$

Khi đó, điểm kỳ vọng của việc đi qua là:

$$V_{\text{cross}}(0.0134) = 80 - 680(0.0134) \approx 70.9.$$

Tổng điểm kỳ vọng của phương án thực hiện phép đo bổ sung là:

$$\begin{aligned} V_{\text{probe}} &= -6 + P(B^+ | A^+)(20) \\ &\quad + P(B^- | A^+)(70.9) \\ &= -6 + 0.254(20) + 0.746(70.9) \\ &\approx 51.96. \end{aligned}$$

So sánh ba lựa chọn:

$$V_{\text{cross}} = -56, \quad V_{\text{detour}} = 20, \quad V_{\text{probe}} \approx 51.96.$$

Vì vậy, robot nên thực hiện phép đo bổ sung. Nếu đầu dò trả về B^+ , robot đi đường vòng, nếu đầu dò trả về B^- , robot đi qua.

Vì sao các đáp án khác sai?

- **A sai** vì bỏ qua xác suất tiên nghiệm $P(H) = 0.04$ khi áp dụng định lý Bayes.
- **C sai** vì mặc dù phép đo không thay đổi nền đá, kết quả của phép đo giúp robot lựa chọn hành động phù hợp hơn với từng trường hợp.
- **D sai** vì 8% là $P(B^+ | \bar{H})$, không phải $P(H | A^+, B^-)$. Giá trị hậu nghiệm đúng sau B^- là khoảng 1.34%.

Kết luận: Thông tin bổ sung có thể làm tăng chất lượng quyết định ngay cả khi phép đo không làm thay đổi trạng thái vật lý của môi trường. Vai trò của xác suất là giúp robot cập nhật mức độ tin tưởng từ các quan sát không chắc chắn, sau đó so sánh điểm kỳ vọng của những quy tắc hành động khác nhau.

III. AIO26M02Q03

Một công ty đang phát triển hệ thống hỗ trợ họp trực tuyến có khả năng tách người dùng khỏi nền thật, thay bằng nền ảo, sau đó phân tích ảnh kết quả để lựa chọn chế độ hiển thị phù hợp. Quy trình tổng quát của hệ thống được minh họa trong Hình 2. Từ ảnh nền và ảnh camera hiện tại, hệ thống tạo mặt nạ để xác định vùng foreground, sau đó kết hợp vùng này với ảnh nền ảo để tạo ảnh đầu ra.



Hình 2: Quy trình tổng quát tách người dùng khỏi nền thật và thay bằng nền ảo.

Trong bài toán này, quy trình trên được mô phỏng bằng các ảnh grayscale kích thước 2×3 , trong đó mỗi phần tử biểu diễn cường độ sáng của một pixel. Ảnh nền được ghi nhận trước khi người dùng xuất hiện, ảnh hiện tại từ camera và ảnh nền ảo lần lượt là

$$B = \begin{bmatrix} 40 & 42 & 41 \\ 80 & 82 & 79 \end{bmatrix}, \quad I = \begin{bmatrix} 42 & 57 & 39 \\ 79 & 120 & 81 \end{bmatrix}, \quad F = \begin{bmatrix} 10 & 10 & 10 \\ 200 & 200 & 200 \end{bmatrix}.$$

Bước 1: Tạo mặt nạ và thay nền.

Hệ thống tính ma trận sai khác $A = |I - B|$ theo từng phần tử. Với ngưỡng $th = 15$, mặt nạ nhị phân M được xác định bởi

$$M_{ij} = \begin{cases} 1, & A_{ij} \geq 15, \\ 0, & A_{ij} < 15. \end{cases}$$

Tại vị trí $M_{ij} = 1$, hệ thống giữ pixel tương ứng từ ảnh camera I . Tại vị trí $M_{ij} = 0$, hệ thống lấy pixel tương ứng từ nền ảo F . Ảnh đầu ra được tính bởi

$$O = M \odot I + (1 - M) \odot F,$$

trong đó $\odot$ là phép nhân theo từng phần tử và $\mathbf{1}_{2 \times 3}$ là ma trận kích thước 2×3 chứa toàn số 1.

Bước 2: Trích xuất đặc trưng.

Ảnh O được làm phẳng theo thứ tự từng hàng, từ trái sang phải và từ trên xuống dưới:

$$x = [O_{11} \ O_{12} \ O_{13} \ O_{21} \ O_{22} \ O_{23}]^T.$$

Vector đặc trưng được tính bởi $z = Wx$, với

$$W = \begin{bmatrix} 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 \\ -1 & 2 & -1 & 1 & -2 & 1 \end{bmatrix},$$

sau đó được chuẩn hóa thành vector đơn vị $\hat{z} = \frac{z}{\|z\|_2}$.

Bước 3: Chọn chế độ hiển thị.

Ba vector mẫu là

$$p_1 = \begin{bmatrix} 1 \\ 7 \\ 3 \end{bmatrix}, \quad p_2 = \begin{bmatrix} 1 \\ 5 \\ 4 \end{bmatrix}, \quad p_3 = \begin{bmatrix} 2 \\ 8 \\ 1 \end{bmatrix}.$$

Với mỗi p_k , hệ thống tạo vector đơn vị $\hat{p}_k = p_k / \|p_k\|_2$ và tính điểm

$$s_k = \hat{z}^T \hat{p}_k = \frac{z^T p_k}{\|z\|_2 \|p_k\|_2}.$$

Hệ thống chọn vector mẫu có điểm lớn nhất. Trong mọi phép tính trung gian, hệ thống sử dụng độ chính xác đầy đủ, còn các thành phần của $\hat{z}$ và các điểm s_k được làm tròn đến bốn chữ số thập phân.

Câu hỏi: Phương án nào mô tả chính xác toàn bộ quá trình tính toán và kết quả của pipeline?

A.

$$M = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 10 & 10 & 10 \\ 200 & 120 & 200 \end{bmatrix}.$$

$$z = \begin{bmatrix} 30 \\ 520 \\ 160 \end{bmatrix}, \quad \hat{z} \approx \begin{bmatrix} 0.0551 \\ 0.9543 \\ 0.2936 \end{bmatrix}.$$

$$(s_1, s_2, s_3) \approx (0.9916, 0.9260, 0.9677).$$

Hệ thống chọn p_1 .

B.

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 10 & 57 & 10 \\ 200 & 120 & 200 \end{bmatrix}.$$

$$z = \begin{bmatrix} 77 \\ 520 \\ 254 \end{bmatrix}, \quad \hat{z} \approx \begin{bmatrix} 0.1319 \\ 0.8907 \\ 0.4351 \end{bmatrix}.$$

$$(s_1, s_2, s_3) \approx (0.9988, 0.9761, 0.9419).$$

Hệ thống chọn p_1 .

C.

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 10 & 57 & 10 \\ 200 & 120 & 200 \end{bmatrix}.$$

$$z = \begin{bmatrix} 77 \\ 520 \\ 254 \end{bmatrix}, \quad \hat{z} \approx \begin{bmatrix} 0.1319 \\ 0.8907 \\ 0.4351 \end{bmatrix}.$$

Nhóm kỹ thuật sử dụng trực tiếp các tích vô hướng

$$(\hat{z}^T p_1, \hat{z}^T p_2, \hat{z}^T p_3) \approx (7.6719, 6.3256, 7.8243).$$

Hệ thống chọn p_3 .

D.

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 42 & 10 & 39 \\ 79 & 200 & 81 \end{bmatrix}.$$

$$z = \begin{bmatrix} 91 \\ 360 \\ -301 \end{bmatrix}, \quad \hat{z} \approx \begin{bmatrix} 0.1904 \\ 0.7531 \\ -0.6297 \end{bmatrix}.$$

$$(s_1, s_2, s_3) \approx (0.4652, 0.2218, 0.6954).$$

Hệ thống chọn p_3 .

Đáp án đúng: B.

Giải thích

Ma trận sai khác là

$$A = |I - B| = \begin{bmatrix} |42 - 40| & |57 - 42| & |39 - 41| \\ |79 - 80| & |120 - 82| & |81 - 79| \end{bmatrix} = \begin{bmatrix} 2 & 15 & 2 \\ 1 & 38 & 2 \end{bmatrix}.$$

Áp dụng điều kiện ngưỡng $A_{ij} \geq 15$, ta được

$$M = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \end{bmatrix}.$$

Tại các vị trí $M = 1$, hệ thống lấy pixel từ I . Tại các vị trí $M = 0$, hệ thống lấy pixel từ F . Do đó,

$$O = \begin{bmatrix} 10 & 57 & 10 \\ 200 & 120 & 200 \end{bmatrix}.$$

Làm phẳng O theo từng hàng thu được

$$x = \begin{bmatrix} 10 \\ 57 \\ 10 \\ 200 \\ 120 \\ 200 \end{bmatrix}.$$

Vector đặc trưng là

$$z = Wx = \begin{bmatrix} 77 \\ 520 \\ 254 \end{bmatrix},$$

vì

$$z_1 = 10 + 57 + 10 = 77,$$

$$z_2 = 200 + 120 + 200 = 520.$$

$$z_3 = -10 + 2(57) - 10 + 200 - 2(120) + 200 = 254.$$

Norm Euclidean của z là

$$\|z\|_2 = \sqrt{77^2 + 520^2 + 254^2} = \sqrt{340845} \approx 583.8193.$$

Vì vậy,

$$\hat{z} = \frac{z}{\|z\|_2} \approx \begin{bmatrix} 0.1319 \\ 0.8907 \\ 0.4351 \end{bmatrix}.$$

Các dot product là

$$z^T p_1 = 4479, \quad z^T p_2 = 3693, \quad z^T p_3 = 4568.$$

Norm của các vector mẫu là

$$\|p_1\|_2 = \sqrt{59}, \quad \|p_2\|_2 = \sqrt{42}, \quad \|p_3\|_2 = \sqrt{69}.$$

Do đó,

$$s_1 = \frac{4479}{\sqrt{340845}\sqrt{59}} \approx 0.9988,$$

$$s_2 = \frac{3693}{\sqrt{340845}\sqrt{42}} \approx 0.9761.$$

$$s_3 = \frac{4568}{\sqrt{340845}\sqrt{69}} \approx 0.9419.$$

Vì $s_1 > s_2 > s_3$, hệ thống chọn p_1 .

Vì sao các đáp án khác sai?

- **A sai** vì đã gán $M_{12} = 0$, trong khi $A_{12} = 15$ thỏa mãn điều kiện $A_{12} \geq 15$. Vì vậy, M_{12} phải bằng 1.
- **C sai** vì chỉ chuẩn hóa z nhưng không chuẩn hóa các vector mẫu p_k . Các giá trị $\hat{z}^T p_k$ vẫn phụ thuộc vào độ dài của p_k , nên không phải cosine similarity. Việc sử dụng các giá trị này dẫn đến lựa chọn sai p_3 .
- **D sai** vì đã đảo ngược quy tắc kết hợp foreground và background. Ảnh trong phương án D tương ứng với công thức


$$O = (\mathbf{1}_{2 \times 3} - M) \odot I + M \odot F,$$

trong khi đề bài yêu cầu lấy pixel từ I tại các vị trí $M = 1$ và lấy pixel từ F tại các vị trí $M = 0$.

IV. AIO26M02Q04

Một nhà máy sử dụng hệ thống AI để kiểm tra chất lượng sản phẩm. Với mỗi sản phẩm, camera thu nhận một vùng ảnh grayscale quanh vị trí nghi ngờ có lỗi. Hệ thống lần lượt phân tích thống kê vùng ảnh, thực hiện cân bằng histogram, kết hợp cảnh báo từ bộ phân tích ảnh với cảnh báo từ cảm biến nhiệt, sau đó đưa ra quyết định phân loại dựa trên chi phí kỳ vọng.

Quy trình tổng quát của hệ thống được trình bày trong Hình 3.



Hình 3: Quy trình tổng quát kiểm tra chất lượng sản phẩm.

Trong sản phẩm đang xét, vùng ảnh grayscale được camera thu nhận là

$$G = \begin{bmatrix} 1 & 1 & 2 & 2 \\ 3 & 3 & 4 & 8 \end{bmatrix}.$$

Chọn ngẫu nhiên đều một trong tám pixel của G và gọi X là mức xám của pixel được chọn. Khi đó, PMF và CDF của X lần lượt được ký hiệu bởi

$$p_X(x) = P(X = x), \quad F_X(t) = P(X \leq t).$$

Chúng ta cần xác định mean μ , median m , population variance $\text{Var}(X)$, standard deviation $\sigma = \sqrt{\text{Var}(X)}$, cùng hai giá trị $p_X(3)$ và $F_X(2)$.

Tám pixel được xem là toàn bộ tổng thể đang phân tích. Vì vậy, population variance được tính với mẫu số $n = 8$, không sử dụng mẫu số $n - 1$. Các kết quả thập phân trong báo cáo được làm tròn đến bốn chữ số sau dấu phẩy.

Bước 1: Phân tích thống kê và cân bằng histogram.

Hệ thống ánh xạ các mức xám sang $L = 10$ mức đầu ra, được đánh số từ 0 đến 9. Với

$$H[b] = F_X(b) = P(X \leq b),$$

mức xám mới được xác định bởi

$$b_{\text{new}} = \lfloor 9H[b] + 0.5 \rfloor.$$

Ánh xạ được tính một lần cho mỗi mức xám khác nhau, sau đó áp dụng cho tất cả pixel có cùng giá trị. Ký hiệu G_{eq} chỉ bức ảnh thu được sau phép ánh xạ này. Histogram đầu ra không bắt buộc phải trở thành phân phối đều hoàn hảo.

Bước 2: Kết hợp cảnh báo và phân loại sản phẩm.

Gọi D là sự kiện sản phẩm có lỗi, N là sự kiện sản phẩm bình thường, A là cảnh báo từ bộ phân tích ảnh và B là cảnh báo từ cảm biến nhiệt. Hai lớp D và N loại trừ nhau và bao phủ toàn bộ các trường hợp sản phẩm. Dữ liệu lịch sử cho biết

$$\begin{aligned} P(D) &= 0.20, & P(N) &= 0.80, \\ P(A | D) &= 0.90, & P(A | N) &= 0.15, \\ P(B | D) &= 0.80, & P(B | N) &= 0.25. \end{aligned}$$

Ở sản phẩm đang xét, cả hai cảnh báo A và B đều xảy ra. Đây là hai quan sát được cho sẵn, không cần suy ra trực tiếp từ ma trận G .

Hệ thống giả định A và B độc lập có điều kiện khi đã biết lớp C , trong đó $C \in \{D, N\}$. Khi đó,

$$P(A, B | C) = P(A | C)P(B | C)$$

Chúng ta cần tính $P(D | A, B)$, tức xác suất hậu nghiệm sản phẩm có lỗi khi cả hai cảnh báo đều xảy ra.

Nếu hệ thống dự đoán sản phẩm có lỗi trong khi sản phẩm thực tế bình thường, chi phí là 2 đơn vị. Nếu hệ thống dự đoán sản phẩm bình thường trong khi sản phẩm thực tế có lỗi, chi phí là 8 đơn vị. Dự đoán đúng có chi phí bằng 0. Hệ thống chọn quyết định có chi phí kỳ vọng nhỏ hơn.

Trong các phương án dưới đây, R_D là chi phí kỳ vọng khi dự đoán sản phẩm có lỗi và R_N là chi phí kỳ vọng khi dự đoán sản phẩm bình thường.

Câu hỏi: Phương án nào chứa đầy đủ và chính xác các kết quả thống kê, cân bằng histogram và quyết định phân loại?

A.

$$(\mu, m, \text{Var}(X), \sigma) = \left(3, 2.5, \frac{36}{7}, 2.2678\right), \quad p_X(3) = \frac{1}{4}, \quad F_X(2) = \frac{1}{4}.$$

$$1 \mapsto 2, \quad 2 \mapsto 5, \quad 3 \mapsto 7, \quad 4 \mapsto 8, \quad 8 \mapsto 9, \quad G_{\text{eq}} = \begin{bmatrix} 2 & 2 & 5 & 5 \\ 7 & 7 & 8 & 9 \end{bmatrix}.$$

$$P(D | A, B) = \frac{96}{101}, \quad (R_D, R_N) = \left(\frac{10}{101}, \frac{768}{101}\right).$$

Hệ thống dự đoán sản phẩm có lỗi.

B.

$$(\mu, m, \text{Var}(X), \sigma) = (3, 2.5, 4.5, 2.1213), \quad p_X(3) = \frac{1}{4}, \quad F_X(2) = \frac{1}{2}.$$

$$1 \mapsto 2, \quad 2 \mapsto 4, \quad 3 \mapsto 6, \quad 4 \mapsto 7, \quad 8 \mapsto 9, \quad G_{\text{eq}} = \begin{bmatrix} 2 & 2 & 4 & 4 \\ 6 & 6 & 7 & 9 \end{bmatrix}.$$

$$P(D | A, B) = \frac{24}{29}, \quad (R_D, R_N) = \left(\frac{48}{29}, \frac{40}{29} \right).$$

Hệ thống dự đoán sản phẩm bình thường.

C.

$$(\mu, m, \text{Var}(X), \sigma) = \left(3, 2.5, \frac{36}{7}, 2.2678 \right), \quad p_X(3) = \frac{1}{4}, \quad F_X(2) = \frac{1}{4}.$$

$$1 \mapsto 2, \quad 2 \mapsto 4, \quad 3 \mapsto 6, \quad 4 \mapsto 7, \quad 8 \mapsto 9, \quad G_{\text{eq}} = \begin{bmatrix} 2 & 2 & 4 & 4 \\ 6 & 6 & 7 & 9 \end{bmatrix}.$$

$$P(D | A, B) = \frac{24}{29}, \quad (R_D, R_N) = \left(\frac{10}{29}, \frac{192}{29} \right).$$

Hệ thống dự đoán sản phẩm có lỗi.

D.

$$(\mu, m, \text{Var}(X), \sigma) = (3, 2.5, 4.5, 2.1213), \quad p_X(3) = \frac{1}{4}, \quad F_X(2) = \frac{1}{2}.$$

$$1 \mapsto 2, \quad 2 \mapsto 5, \quad 3 \mapsto 7, \quad 4 \mapsto 8, \quad 8 \mapsto 9, \quad G_{\text{eq}} = \begin{bmatrix} 2 & 2 & 5 & 5 \\ 7 & 7 & 8 & 9 \end{bmatrix}.$$

$$P(D | A, B) = \frac{24}{29}, \quad (R_D, R_N) = \left(\frac{10}{29}, \frac{192}{29} \right).$$

Hệ thống dự đoán sản phẩm có lỗi.

Đáp án đúng: D.

Giải thích

Các mức xám sau khi sắp xếp theo thứ tự tăng dần là

$$1, 1, 2, 2, 3, 3, 4, 8.$$

Do đó,

$$\mu = \frac{1 + 1 + 2 + 2 + 3 + 3 + 4 + 8}{8} = 3, \quad m = \frac{2 + 3}{2} = 2.5.$$

Vì đề bài yêu cầu population variance với mẫu số $n = 8$,

$$\begin{aligned}\text{Var}(X) &= \frac{2(1-3)^2 + 2(2-3)^2 + 2(3-3)^2 + (4-3)^2 + (8-3)^2}{8} \\ &= \frac{36}{8} = 4.5.\end{aligned}$$

Vì vậy, $\sigma = \sqrt{4.5} \approx 2.1213$.

Giá trị 3 xuất hiện hai lần trong tám pixel, nên $p_X(3) = 2/8 = 1/4$. Có bốn pixel có mức xám không lớn hơn 2, nên

$$F_X(2) = P(X \leq 2) = \frac{4}{8} = \frac{1}{2}.$$

Cân bằng histogram.

Các giá trị CDF và mức xám mới tương ứng là

b	1	2	3	4	8
$H[b]$	$\frac{2}{8}$	$\frac{4}{8}$	$\frac{6}{8}$	$\frac{7}{8}$	1
b_{new}	2	5	7	8	9

Chẳng hạn,

$$2_{\text{new}} = \left\lceil 9 \left(\frac{4}{8} \right) + 0.5 \right\rceil = 5.$$

Do đó,

$$G_{\text{eq}} = \begin{bmatrix} 2 & 2 & 5 & 5 \\ 7 & 7 & 8 & 9 \end{bmatrix}.$$

Tính xác suất hậu nghiệm.

Theo giả định độc lập có điều kiện,

$$P(A, B \mid D) = 0.90 \times 0.80 = 0.72,$$

$$P(A, B \mid N) = 0.15 \times 0.25 = 0.0375.$$

Kết hợp likelihood với prior của từng lớp,

$$P(D, A, B) = 0.20 \times 0.72 = 0.144,$$

$$P(N, A, B) = 0.80 \times 0.0375 = 0.03.$$

Vì D và N là hai lớp loại trừ nhau và bao phủ toàn bộ các trường hợp,

$$P(A, B) = P(D, A, B) + P(N, A, B) = 0.174.$$

Do đó,

$$P(D | A, B) = \frac{0.144}{0.174} = \frac{24}{29},$$

và

$$P(N | A, B) = 1 - \frac{24}{29} = \frac{5}{29}.$$

Ra quyết định theo chi phí kỳ vọng.

Khi dự đoán sản phẩm có lỗi, chi phí chỉ phát sinh nếu sản phẩm thực tế bình thường:

$$R_D = 2P(N | A, B) = 2 \left(\frac{5}{29} \right) = \frac{10}{29}.$$

Khi dự đoán sản phẩm bình thường, chi phí chỉ phát sinh nếu sản phẩm thực tế có lỗi:

$$R_N = 8P(D | A, B) = 8 \left(\frac{24}{29} \right) = \frac{192}{29}.$$

Vì $R_D < R_N$, hệ thống dự đoán sản phẩm có lỗi.

Vì sao các đáp án khác sai?

- **A sai** vì sử dụng sample variance với mẫu số $n - 1 = 7$ thay cho population variance với mẫu số $n = 8$. Phương án này cũng nhầm $F_X(2) = P(X \leq 2)$ với $P(X = 2)$, đồng thời bỏ qua prior của hai lớp khi tính xác suất hậu nghiệm.
- **B sai** vì áp dụng ánh xạ $\lfloor 9H[b] \rfloor$ thay vì $\lfloor 9H[b] + 0.5 \rfloor$. Ngoài ra, phương án này tính chi phí bằng xác suất của lớp được dự đoán thay vì xác suất của trường hợp dự đoán sai.
- **C sai** vì sử dụng sample variance, nhầm CDF với xác suất tại một điểm và áp dụng sai quy tắc làm tròn trong cân bằng histogram. Phần tính xác suất hậu nghiệm và chi phí kỳ vọng của phương án này đúng, nhưng toàn bộ báo cáo vẫn không chính xác.

V. AIO26M02Q05

Giám sát nước thải được dùng như một nguồn thông tin bổ sung trong y tế công cộng. Kết quả xét nghiệm mẫu nước thải thu tại nhà máy xử lý có thể giúp phát hiện sớm khi mức lưu hành của một số tác nhân gây bệnh trong cộng đồng ở mức cao. Tuy nhiên, dữ liệu này chỉ hỗ trợ ra quyết định ở cấp khu vực và không được dùng để chẩn đoán một cá nhân.

Ba khu vực của một thành phố cùng đưa nước thải về một nhà máy xử lý. Trước cuộc họp phân bổ nguồn lực cho tuần tiếp theo, gọi X là số khu vực có mức lưu hành virus cao. Khi chưa có kết quả xét nghiệm mới nhất, nhóm phân tích sử dụng prior distribution trong Bảng 4.

Bảng 4: Phân phối xác suất ban đầu của số khu vực có mức lưu hành virus cao.

x	0	1	2	3
$P(X = x)$	0.50	0.30	0.15	0.05

Từ prior distribution này, phòng y tế cần xác định kỳ vọng và mức độ phân tán của số khu vực có mức lưu hành virus cao, đồng thời tính xác suất số khu vực có mức lưu hành virus cao không vượt quá một. Giá trị kỳ vọng được tính bởi

$$E(X) = \sum_{x=0}^3 xP(X = x).$$

Đối với X , variance được tính bởi

$$\text{Var}(X) = E(X^2) - [E(X)]^2,$$

và standard deviation được xác định bởi

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

Xác suất có không quá một khu vực có mức lưu hành virus cao được viết dưới dạng

$$F_X(1) = P(X \leq 1).$$

Cùng ngày, kết quả xét nghiệm nước thải cho thấy tín hiệu của một chỉ dấu virus đã vượt ngưỡng cảnh báo. Ký hiệu A^+ là sự kiện xét nghiệm phát cảnh báo. Giá trị likelihood của A^+ thay đổi theo số khu vực thật sự có mức lưu hành virus cao như trong Bảng 5.

Bảng 5: Likelihood của kết quả cảnh báo theo số khu vực có mức lưu hành virus cao.

x	0	1	2	3
$P(A^+ X = x)$	0.05	0.30	0.70	0.90

Trong tình huống hiện tại, phòng xét nghiệm đã ghi nhận kết quả A^+ . Sau khi quan sát kết quả này, nhóm phân tích cập nhật phân phối xác suất của X , tức số khu vực có mức lưu hành virus

cao, trên bốn giá trị có thể có là 0, 1, 2, 3. Với mỗi $x \in \{0, 1, 2, 3\}$, một thành phần của posterior distribution được tính bởi

$$P(X = x | A^+) = \frac{P(A^+ | X = x)P(X = x)}{\sum_{j=0}^3 P(A^+ | X = j)P(X = j)}.$$

Phòng y tế đang cân nhắc hai kế hoạch chuẩn bị nguồn lực.

1. Kế hoạch ứng phó linh hoạt.

Thành phố bố trí trước một đội phản ứng lưu động với chi phí quy đổi bằng 3 đơn vị. Đội này có thể phục vụ tối đa một khu vực. Nếu có nhiều hơn một khu vực cần hỗ trợ, mỗi khu vực ngoài khu vực đầu tiên làm phát sinh thêm 6 đơn vị chi phí. Chi phí của kế hoạch này là

$$C_T(x) = 3 + 6 \max(x - 1, 0).$$

Do đó

$$C_T(0) = 3, \quad C_T(1) = 3, \quad C_T(2) = 9, \quad C_T(3) = 15.$$

2. Kế hoạch ứng phó diện rộng.

Thành phố chuẩn bị đồng thời nguồn lực cho cả ba khu vực. Kế hoạch này có chi phí cố định bằng 7 đơn vị trong mọi trường hợp. Vì vậy

$$C_B(x) = 7.$$

Trước khi có A^+ , chi phí kỳ vọng được tính theo prior distribution. Sau khi có A^+ , chi phí kỳ vọng phải được tính theo posterior distribution. Ở mỗi thời điểm, phòng y tế chọn kế hoạch có chi phí kỳ vọng nhỏ hơn.

Câu hỏi: Phương án nào dưới đây trình bày chính xác các đại lượng thống kê, posterior distribution và kế hoạch được lựa chọn trước và sau khi quan sát A^+ ?

- A. Phân phối ban đầu có $E(X) = 0.75$, $\text{Var}(X) = 0.7875$, $\sigma_X \approx 0.8874$ và $F_X(1) = 0.80$. Sau A^+ , posterior distribution là

$$\left(\frac{5}{53}, \frac{18}{53}, \frac{21}{53}, \frac{9}{53} \right).$$

Trước cảnh báo, $E[C_T(X)] = 4.5 < 7$. Sau cảnh báo, $E[C_T(X) | A^+] = 393/53 \approx 7.42 > 7$. Vì vậy, phòng y tế dùng kế hoạch ứng phó linh hoạt trước A^+ và chuyển sang kế hoạch ứng phó diện rộng sau A^+ .

- B.** Phân phối ban đầu có $E(X) = 0.75$, $\text{Var}(X) = 1.35$, $\sigma_X \approx 1.1619$ và $F_X(1) = 0.80$. Sau A^+ , posterior distribution là

$$\left(\frac{5}{53}, \frac{18}{53}, \frac{21}{53}, \frac{9}{53} \right).$$

Trước cảnh báo, $E[C_T(X)] = 4.5 < 7$. Sau cảnh báo, $E[C_T(X) | A^+] = 393/53 \approx 7.42 > 7$. Vì vậy, phòng y tế dùng kế hoạch ứng phó linh hoạt trước A^+ và chuyển sang kế hoạch ứng phó diện rộng sau A^+ .

- C.** Phân phối ban đầu có $E(X) = 0.75$, $\text{Var}(X) = 0.7875$, $\sigma_X \approx 0.8874$ và $F_X(1) = 0.80$. Sau A^+ , posterior distribution là

$$\left(\frac{1}{39}, \frac{6}{39}, \frac{14}{39}, \frac{18}{39} \right).$$

Trước cảnh báo, $E[C_T(X)] = 4.5 < 7$. Sau cảnh báo, $E[C_T(X) | A^+] = 417/39 \approx 10.69 > 7$. Vì vậy, phòng y tế dùng kế hoạch ứng phó linh hoạt trước A^+ và chuyển sang kế hoạch ứng phó diện rộng sau A^+ .

- D.** Phân phối ban đầu có $E(X) = 0.75$, $\text{Var}(X) = 0.7875$, $\sigma_X \approx 0.8874$ và $F_X(1) = 0.80$. Sau A^+ , posterior distribution là

$$\left(\frac{5}{53}, \frac{18}{53}, \frac{21}{53}, \frac{9}{53} \right).$$

Trước cảnh báo, $E[C_T(X)] = 4.5 < 7$. Vì kết quả xét nghiệm không làm thay đổi trạng thái thực tế, phương án này cho rằng chi phí kỳ vọng của kế hoạch ứng phó linh hoạt vẫn bằng 4.5 sau A^+ . Do đó, phòng y tế tiếp tục dùng kế hoạch ứng phó linh hoạt ở cả hai thời điểm.

Đáp án đúng: A.

Giải thích

Từ prior distribution

$$\begin{aligned} E(X) &= 0(0.50) + 1(0.30) + 2(0.15) + 3(0.05) \\ &= 0.75, \end{aligned}$$

và

$$\begin{aligned} E(X^2) &= 0^2(0.50) + 1^2(0.30) + 2^2(0.15) + 3^2(0.05) \\ &= 1.35. \end{aligned}$$

Do đó

$$\text{Var}(X) = 1.35 - (0.75)^2 = 0.7875,$$

$$\sigma_X = \sqrt{0.7875} \approx 0.8874,$$

và

$$F_X(1) = P(X \leq 1) = 0.50 + 0.30 = 0.80.$$

Trước khi có kết quả xét nghiệm mới

$$\begin{aligned} E[C_T(X)] &= 3(0.50) + 3(0.30) + 9(0.15) + 15(0.05) \\ &= 4.5, \end{aligned}$$

trong khi

$$E[C_B(X)] = 7.$$

Vì $4.5 < 7$, kế hoạch ứng phó linh hoạt có chi phí kỳ vọng thấp hơn.

Sau khi ghi nhận A^+

$$\begin{aligned} P(A^+) &= \sum_{x=0}^3 P(A^+ | X = x)P(X = x) \\ &= 0.05(0.50) + 0.30(0.30) + 0.70(0.15) + 0.90(0.05) \\ &= 0.265. \end{aligned}$$

Áp dụng Bayes cho bốn trường hợp thu được

$$(P(X = 0 | A^+), P(X = 1 | A^+), P(X = 2 | A^+), P(X = 3 | A^+)) = \left(\frac{5}{53}, \frac{18}{53}, \frac{21}{53}, \frac{9}{53} \right).$$

Chi phí kỳ vọng của kế hoạch ứng phó linh hoạt sau A^+ là

$$\begin{aligned}
 E[C_T(X) \mid A^+] &= 3 \left(\frac{5}{53} \right) + 3 \left(\frac{18}{53} \right) + 9 \left(\frac{21}{53} \right) + 15 \left(\frac{9}{53} \right) \\
 &= \frac{393}{53} \\
 &\approx 7.42.
 \end{aligned}$$

Kế hoạch ứng phó diện rộng vẫn có chi phí bằng 7. Vì

$$7 < \frac{393}{53} \approx 7.42,$$

phòng y tế chuyển sang kế hoạch ứng phó diện rộng sau kết quả cảnh báo.

Bảng 6: Kế hoạch được lựa chọn trước và sau kết quả cảnh báo.

Thời điểm	$E[C_T]$	$E[C_B]$	Kế hoạch được chọn
Trước A^+	4.5	7	Ứng phó linh hoạt
Sau A^+	$393/53 \approx 7.42$	7	Ứng phó diện rộng

Vì sao các đáp án khác sai?


- **B sai** vì 1.35 là $E(X^2)$, không phải $\text{Var}(X)$. Để tính variance, cần trừ thêm $[E(X)]^2$.
- **C sai** vì likelihood không phải posterior probability. Mỗi likelihood phải được nhân với prior tương ứng trước khi chuẩn hóa.
- **D sai** vì kết quả xét nghiệm làm thay đổi phân phối xác suất dùng để tính chi phí kỳ vọng. Trạng thái thật có thể không đổi nhưng quyết định phù hợp vẫn có thể thay đổi khi có thêm thông tin.

Kết luận

Kết quả A^+ không làm thay đổi trạng thái thực tế của các khu vực, nhưng làm thay đổi mức độ tin tưởng của nhóm phân tích đối với từng giá trị có thể có của số khu vực có mức lưu hành virus cao. Vì vậy, nhóm phụ trách cần cập nhật posterior distribution và tính lại chi phí kỳ vọng trước khi lựa chọn phương án phân bổ nguồn lực.

VI. AIO26M02Q06

Bộ phận quản lý quan hệ khách hàng CRM (Customer Relationship Management) của một nhà bán lẻ quà tặng trực tuyến đang chuẩn bị danh sách khách hàng cho chiến dịch quý tới. Doanh nghiệp muốn dùng lịch sử giao dịch để xác định nhóm chăm sóc phù hợp, đồng thời loại các tài khoản có hành vi mua sỉ hoặc B2B khỏi mô hình dành cho khách hàng bán lẻ.



Hình 4: Minh họa phân cụm khách hàng bán lẻ bằng K-Means.

Trong dữ liệu, một số tài khoản tập trung phần lớn giá trị mua hàng vào một số ít mã sản phẩm SKU (Stock Keeping Unit). Các tài khoản này thường có đặc điểm giao dịch gần với hành vi mua sỉ. Hệ thống sử dụng SKU_HHI để tách nhóm trước khi chạy K-Means. Theo quy tắc hiện hành, nếu

$$\text{SKU_HHI} > 0.5$$

thì tài khoản được chuyển sang quy trình B2B (Business-to-Business) và không tiếp tục qua model retail.

Ba khách hàng mới cần được phân luồng và gán cluster trước khi danh sách chiến dịch được chốt. Thông tin được trình bày trong Bảng 7.

Bảng 7: Thông tin của ba khách hàng mới.

Khách hàng	SKU_HHI	NumOrders	Recency	ReturnRate	QuarterConcentration
<i>A</i>	0.22	8	18	0.25	0.50
<i>B</i>	0.18	1	128	0	1.00
<i>D</i>	0.72	6	24	0	0.80

Trong Bảng 7, NumOrders là tổng số đơn hàng của khách hàng. Recency là số ngày tính từ lần mua gần nhất đến ngày tham chiếu. ReturnRate là tỷ lệ đơn bị trả lại. QuarterConcentration là tỷ lệ giao dịch thuộc quý có nhiều giao dịch nhất.

Ngoài các thông tin trong bảng, mô hình còn sử dụng MonthlyOrderRate. Feature này đo số đơn trung bình mỗi tháng trong khoảng thời gian khách hàng thực sự hoạt động.

Để phép tính trong câu hỏi không quá dài, bước gán cluster bằng K-Means được mô phỏng bằng một mô hình rút gọn gồm bốn feature theo thứ tự Recency, MonthlyOrderRate, ReturnRate và QuarterConcentration. Các vector khách hàng và các centroid dưới đây đều nằm trong cùng một không gian đặc trưng bốn chiều sau khi đi qua preprocessing pipeline đã được fit trên training data.

$$z_A = \begin{bmatrix} -0.8 \\ 1.2 \\ 1.9 \\ -0.2 \end{bmatrix}, \quad z_B = \begin{bmatrix} 1.5 \\ -1.1 \\ -0.8 \\ 1.4 \end{bmatrix}.$$

Bốn cluster của K-Means được ký hiệu là C_0 , C_1 , C_2 và C_3 . Với $k \in \{0, 1, 2, 3\}$, gọi c_k là vector centroid của cluster C_k . Các centroid trong cùng không gian sau preprocessing là

$$c_0 = \begin{bmatrix} -0.4 \\ 1.1 \\ -0.7 \\ 1.5 \end{bmatrix}, \quad c_1 = \begin{bmatrix} -0.7 \\ 1.0 \\ 1.8 \\ -0.3 \end{bmatrix}, \quad c_2 = \begin{bmatrix} 1.4 \\ -1.2 \\ -0.9 \\ 1.3 \end{bmatrix}, \quad c_3 = \begin{bmatrix} -0.2 \\ -0.2 \\ -0.7 \\ -0.4 \end{bmatrix}.$$

Mỗi khách hàng được gán vào cluster C_k có squared Euclidean distance đến centroid c_k nhỏ nhất:

$$d_k^2(z) = \|z - c_k\|_2^2 = \sum_{r=1}^4 (z_r - c_{kr})^2.$$

Trong công thức, z_r là thành phần thứ r của vector khách hàng z , còn c_{kr} là thành phần thứ r của centroid c_k .

Một số khoảng cách đã được tính sẵn trong Bảng 8. Hai ô còn thiếu cần được tính từ vector khách hàng và centroid tương ứng.

Bảng 8: Squared Euclidean distance từ hai khách hàng retail đến bốn centroid.

Khách hàng	C_0	C_1	C_2	C_3
<i>A</i>	9.82	?	20.69	9.12
<i>B</i>	8.47	18.90	?	6.95

Dựa trên dữ liệu giao dịch gốc, bộ phận CRM đã xây dựng profile và xác định chương trình chăm sóc phù hợp cho từng cluster như trong Bảng 9. Các nhãn C_0 , C_1 , C_2 và C_3 chỉ dùng để định danh cluster, không biểu thị thứ hạng hoặc giá trị tương đối của khách hàng.

Bảng 9: **Profile và chương trình chăm sóc của bốn cluster retail.**

Cluster	Profile	Đặc điểm chính	Chương trình
C_0	<i>Seasonal Intensives</i>	Mua tập trung vào một giai đoạn nhất định trong năm.	P. Chiến dịch theo mùa.
C_1	<i>High-Return Actives</i>	Mua thường xuyên, mới mua gần đây và có ReturnRate cao.	Q. Giảm tỷ lệ trả hàng và duy trì khách hàng.
C_2	<i>One-Time Explorers</i>	Thường chỉ mua một lần và đã lâu chưa quay lại.	R. Khuyến khích lần mua thứ hai.
C_3	<i>Occasional Loyalists</i>	Mua không quá thường xuyên nhưng tương đối ổn định và ít trả hàng.	S. Chăm sóc khách hàng định kỳ.

Câu hỏi: Phương án nào dưới đây phân luồng chính xác tài khoản B2B, tính đúng hai khoảng cách còn thiếu, đồng thời gán cluster và lựa chọn chương trình chăm sóc phù hợp cho các khách hàng bán lẻ?

- A. Khách hàng D vẫn được đưa vào K-Means vì một tài khoản khác biệt đủ lớn có thể tự hình thành cluster riêng. Hai ô còn thiếu lần lượt là 0.07 và 0.04. Do đó, A thuộc C_1 và nhận Chương trình Q, còn B thuộc C_2 và nhận Chương trình R. **QuarterConcentration** bằng 1.00 của B chưa đủ để kết luận hành vi mùa vụ vì khách hàng này chỉ có một đơn. Sau đó, danh sách được chuyển sang CRM.
- B. Khách hàng D được chuyển sang quy trình B2B trước khi chạy K-Means cho nhóm retail. Hai ô còn thiếu lần lượt là 0.07 và 0.04. Khách hàng A thuộc C_1 nhưng nên nhận Chương trình S vì tỷ lệ trả hàng cao làm giảm hiệu quả chăm sóc. Khách hàng B thuộc C_2 nhưng nên nhận Chương trình P vì toàn bộ giao dịch nằm trong một quý. Đây là cách phân bổ phù hợp khi ưu tiên các nhóm ít rủi ro hơn.
- C. Khách hàng D được chuyển sang quy trình B2B trước khi chạy K-Means cho nhóm retail. Hai ô còn thiếu lần lượt là 0.07 và 0.04. Do đó, A thuộc C_1 và nhận Chương trình Q, còn B thuộc C_2 và nhận Chương trình R. **ReturnRate** cao của A là vấn đề cần giảm, không phải lý do để chuyển khách hàng sang một chương trình khác. **QuarterConcentration** bằng 1.00 của B chưa đủ để kết luận khách hàng có hành vi mua theo mùa, vì khách hàng này mới chỉ có một đơn hàng.
- D. Khách hàng D được chuyển sang quy trình B2B trước khi chạy K-Means cho nhóm retail. Vì dữ liệu ban đầu và centroid đều mô tả cùng các hành vi mua hàng, hệ thống có thể so sánh trực tiếp mà không cần đưa dữ liệu qua preprocessing pipeline. Theo cách này, A thuộc C_3 và nhận Chương trình S, còn B thuộc C_2 và nhận Chương trình R. Preprocessing pipeline chỉ cần dùng khi xây dựng model, không cần áp dụng lại khi có khách hàng mới.

Đáp án đúng: C.

Giải thích

Khách hàng D có

$$\text{SKU_HHI} = 0.72 > 0.5.$$

Do đó, tài khoản D được chuyển sang quy trình B2B trước khi chạy K-Means dành cho retail. Khách hàng A và B có SKU_HHI không vượt quá 0.5 nên tiếp tục được xử lý bằng model retail. Ô còn thiếu của khách hàng A là

$$\begin{aligned} d_1^2(z_A) &= (-0.8 + 0.7)^2 + (1.2 - 1.0)^2 \\ &\quad + (1.9 - 1.8)^2 + (-0.2 + 0.3)^2 \\ &= 0.01 + 0.04 + 0.01 + 0.01 \\ &= 0.07. \end{aligned}$$

Vì 0.07 nhỏ hơn 9.82, 20.69 và 9.12, khách hàng A được gán vào C_1 . Profile *High-Return Actives* cho thấy đây là nhóm vẫn mua thường xuyên và mới mua gần đây, nhưng có tỷ lệ trả hàng cao. Chương trình Q phù hợp vì doanh nghiệp vừa cần giữ chân khách hàng, vừa cần giảm nguyên nhân gây trả hàng.

Ô còn thiếu của khách hàng B là

$$\begin{aligned} d_2^2(z_B) &= (1.5 - 1.4)^2 + (-1.1 + 1.2)^2 \\ &\quad + (-0.8 + 0.9)^2 + (1.4 - 1.3)^2 \\ &= 0.01 + 0.01 + 0.01 + 0.01 \\ &= 0.04. \end{aligned}$$

Vì 0.04 nhỏ hơn 8.47, 18.90 và 6.95, khách hàng B được gán vào C_2 . Khách hàng này chỉ có một đơn và Recency bằng 128 ngày. Do đó, Chương trình R phù hợp hơn một chiến dịch mùa vụ.

Mặc dù QuarterConcentration của B bằng 1.00, giá trị này chưa đủ để kết luận khách hàng có thói quen mua theo mùa. Khi chỉ có một đơn, toàn bộ giao dịch đương nhiên nằm trong cùng một quý. Vì vậy, feature này phải được đọc cùng với NumOrders và Recency.

Bảng 10: Kết quả xử lý ba khách hàng mới.

Khách hàng	Kết quả	Chương trình
A	C_1 <i>High-Return Actives</i>	Q
B	C_2 <i>One-Time Explorers</i>	R
D	B2B	Quy trình riêng

Vì sao các đáp án khác sai?

- **A sai** vì khách hàng D đã thỏa quy tắc tách B2B. Nếu vẫn đưa tài khoản này vào K-Means dành cho retail, hệ thống không còn tuân theo phạm vi mà model đã được xây dựng để xử lý.

- **B sai** vì bảng 9 quy định cụm C_1 sử dụng chương trình Q. **ReturnRate** cao chính là đặc điểm khiến chương trình giảm tỷ lệ trả hàng và duy trì khách hàng trở nên phù hợp. Ngoài ra, **QuarterConcentration** bằng 1.00 của B chủ yếu phản ánh việc khách hàng này chỉ có một đơn hàng, chưa đủ để kết luận hành vi mua theo mùa.
- **D sai** vì dữ liệu ban đầu và centroid không nằm trong cùng một không gian. Mọi khách hàng mới phải đi qua preprocessing pipeline đã được thiết lập từ training data trước khi tính khoảng cách.

Kết luận

Quy trình đưa khách hàng mới vào hệ thống cần giữ đúng ba bước. Tài khoản ngoài phạm vi retail được chuyển sang B2B. Các khách hàng còn lại đi qua preprocessing pipeline rồi được gán vào centroid gần nhất. Cuối cùng, bộ phận CRM cần đọc toàn bộ profile của cluster khi lựa chọn chương trình chăm sóc, thay vì đưa ra quyết định dựa trên một feature riêng lẻ.


VII. AIO26M02Q07

Một nền tảng streaming nhạc đang phát triển chức năng “bài hát tương tự” cho catalog dự kiến đạt khoảng 100 triệu track. Mỗi track được biểu diễn bằng một vector embedding, cho phép hệ thống tìm các track có vị trí gần nhau trong không gian vector.


Tầng vector retrieval trước hết lấy một tập ứng viên lớn hơn 50 track. Sau khi loại các track không phù hợp do giới hạn quốc gia, bản quyền hoặc trạng thái phát hành, những ứng viên còn lại được chuyển sang bước personalization và ranking.

Trước khi benchmark trên music embeddings và hạ tầng serving thực tế, nhóm thử nghiệm HNSW và IVF-Flat trên SIFT1M trong cùng một điều kiện. Mục tiêu là chọn các cấu hình sơ bộ để tiếp tục đánh giá, chưa phải xác định cấu hình production cuối cùng.

HNSW



IVFFlat



Hai phương pháp ANN được sử dụng trong benchmark là HNSW và IVF-Flat:

- **HNSW** tổ chức các vector thành một đồ thị nhiều tầng và tìm kiếm bằng cách di chuyển qua các vector lân cận. Tầng efSearch thường làm tăng Recall nhưng cũng làm tăng chi phí truy vấn.

- **IVF-Flat** chia các vector vào nhiều inverted lists và chỉ tìm kiếm trong một số lists gần query nhất. Tăng **nprobe** thường làm tăng Recall nhưng cũng làm tăng lượng dữ liệu cần duyệt.

Để so sánh hai phương pháp trong cùng một quy trình, benchmark được thiết lập như sau:

- Sử dụng 1,000,000 base vectors;
- Mỗi vector có 128 chiều;
- Sử dụng Euclidean distance;
- Đánh giá trên cùng 1,000 query IDs cố định;
- Exact top-50 được lấy từ ground-truth file;

Với tập truy vấn Q , Recall@50 được định nghĩa là:

$$\text{Recall@50} = \frac{1}{|Q|} \sum_{q \in Q} \frac{|\text{ANNTop50}(q) \cap \text{ExactTop50}(q)|}{50}.$$

Recall@50 đo tỷ lệ các hàng xóm thuộc exact top-50 được ANN tìm lại.

Do vòng benchmark trên music embeddings cần nhiều tài nguyên hơn, nhóm kỹ thuật đặt ngưỡng sàng lọc là:

$$\text{Recall@50} \geq 0.98.$$

Ngưỡng này được dùng để loại các cấu hình sai lệch quá nhiều so với exact search trước vòng benchmark trên dữ liệu âm nhạc. Đây chỉ là ngưỡng sàng lọc, không phải yêu cầu production.

Kết quả được trình bày trong Bảng 11.

Bảng 11: Recall@50 của các operating point trong vòng implementation screening

Index family	Operating point	Recall@50
HNSW	efSearch=50	0.886
HNSW	efSearch=100	0.960
HNSW	efSearch=200	0.990
HNSW	efSearch=400	0.998
IVF-Flat	nprobe=1	0.331
IVF-Flat	nprobe=4	0.650
IVF-Flat	nprobe=16	0.899
IVF-Flat	nprobe=64	0.992

Câu hỏi: Nhóm muốn đạt $\text{Recall@50} \geq 0.98$ nhưng không tăng chi phí tìm kiếm nhiều hơn mức cần thiết. Dựa trên kết quả benchmark, kết luận nào sau đây là phù hợp nhất?

- A. Giữ HNSW với $efSearch=400$ và IVF-Flat với $nprobe=64$ vì đây là hai operating point có Recall@50 cao nhất, sau đó sử dụng trực tiếp các cấu hình này trong production.
- B. Giữ HNSW với $efSearch=200$ và IVF-Flat với $nprobe=64$ làm danh sách sơ bộ, sau đó kiểm tra thêm các giá trị trung gian và benchmark lại trên music embeddings trước khi đưa ra quyết định production.
- C. Giữ HNSW với $efSearch=100$ và IVF-Flat với $nprobe=16$ vì search parameter nhỏ hơn quan trọng hơn việc đạt ngưỡng Recall@50.
- D. Giữ HNSW với $efSearch=200$ và IVF-Flat với $nprobe=64$, đồng thời kết luận rằng hai cấu hình này là các operating point tối ưu trên toàn bộ không gian tham số.

Đáp án đúng: B.

Giải thích

- **Vì sao đáp án B đúng?**

Trong HNSW, $efSearch=200$ là giá trị nhỏ nhất trong số các operating point đã benchmark đạt ngưỡng:

$$0.990 \geq 0.98.$$

Trong IVF-Flat, $nprobe=64$ là giá trị nhỏ nhất trong số các operating point đã benchmark đạt ngưỡng:

$$0.992 \geq 0.98.$$

Tuy nhiên, grid hiện tại chưa có các giá trị trung gian giữa $efSearch=100$ và $efSearch=200$, cũng như giữa $nprobe=16$ và $nprobe=64$. Vì vậy, hai cấu hình này chỉ nên được xem là danh sách sơ bộ cho vòng đánh giá tiếp theo, không phải cấu hình production đã được xác nhận.

- **Vì sao A sai?**

HNSW với $efSearch=400$ đạt Recall@50 cao nhất trong các điểm đã đo, nhưng không tuân theo quy tắc chọn search parameter nhỏ nhất đã đạt ngưỡng. Ngoài ra, benchmark trên SIFT1M chưa đủ để xác nhận cấu hình production cho music embeddings.

- **Vì sao C sai?**

HNSW với $efSearch=100$ chỉ đạt Recall@50 = 0.960, còn IVF-Flat với $nprobe=16$ chỉ đạt Recall@50 = 0.899. Cả hai đều không đạt ngưỡng sàng lọc 0.98.

- **Vì sao D sai?**


HNSW với $efSearch=200$ và IVF-Flat với $nprobe=64$ là các điểm đạt ngưỡng thấp nhất trong grid hiện tại, nhưng chưa chắc là các operating point tối ưu. Các giá trị trung gian chưa được đo và kết quả cũng chưa được xác nhận trên music embeddings hoặc serving hardware thực tế.

Tham chiếu: [Google Drive](#)

VIII. AIO26M02Q08

Một công ty bán lẻ muốn chia khách hàng thành các nhóm có hành vi tương tự nhau để xây dựng chiến dịch marketing phù hợp cho từng nhóm. Mỗi khách hàng được mô tả bằng ba đặc trưng RFM:

- **Recency**: số ngày kể từ lần mua hàng gần nhất đến ngày đánh giá;
- **Frequency**: số hóa đơn khác nhau của khách hàng trong 365 ngày gần nhất;
- **Monetary**: tổng số tiền khách hàng đã chi tiêu trong 365 ngày gần nhất.



Dữ liệu được lấy từ bộ **Online Retail II**, bao gồm các giao dịch từ ngày 01/12/2009 đến ngày 09/12/2011.

Recency được tính từ toàn bộ lịch sử giao dịch trước ngày đánh giá để vẫn nhận diện được những khách hàng đã lâu không quay lại. Trong khi đó, **Frequency** và **Monetary** chỉ được tính trong 365 ngày gần nhất nhằm phản ánh hành vi mua hàng hiện tại.

Nhóm xây dựng hai snapshot với lịch sử tích lũy:

- **Tập huấn luyện**: ngày 10/12/2010;
- **Tập đánh giá**: ngày 10/12/2011.

Tại mỗi thời điểm, dữ liệu bao gồm tất cả khách hàng đã từng xuất hiện trước ngày đánh giá. Khách hàng không mua hàng trong 365 ngày gần nhất vẫn được giữ lại với **Frequency** = 0 và **Monetary** = 0, trong khi **Recency** tiếp tục tăng theo thời gian.

Tập đánh giá gồm 5878 khách hàng, với **Recency** nằm trong khoảng từ 1 đến 739 ngày:

- 2698 khách hàng cũ vẫn mua hàng trong 365 ngày gần nhất;
- 1614 khách hàng cũ không mua hàng trong 365 ngày gần nhất;
- 1566 khách hàng mới xuất hiện sau thời điểm tạo tập huấn luyện.

Nhóm 1614 khách hàng không hoạt động có cùng $\text{Frequency} = 0$ và $\text{Monetary} = 0$, nên việc phân biệt các khách hàng trong nhóm này chủ yếu dựa trên Recency .

Các giá trị Frequency và Monetary có phân phối lệch phải và chứa một số khách hàng có giá trị rất lớn. Vì vậy, nhóm thử ba phương pháp tiền xử lý:

- **Raw:** sử dụng trực tiếp ba đặc trưng RFM mà không biến đổi;
- **Log+Std:** áp dụng hàm $\log_{1p}$ cho Frequency và Monetary , sau đó chuẩn hóa cả ba đặc trưng bằng StandardScaler ;
- **Win+Log+Rob:** giới hạn Frequency và Monetary tại phân vị 99%, áp dụng $\log_{1p}$, sau đó chuẩn hóa cả ba đặc trưng bằng RobustScaler .

Mỗi phương pháp tiền xử lý được kết hợp với $K \in \{3, 4, 5\}$, tạo thành chín cấu hình. Các tham số tiền xử lý chỉ được học từ tập huấn luyện, sau đó được dùng để biến đổi tập đánh giá trước khi mỗi khách hàng được gán vào centroid gần nhất.

Đối với mỗi cấu hình, K-Means được fit với 10 random seed và $n_init = 10$. Mô hình có inertia trên tập huấn luyện thấp nhất được chọn làm **mô hình tham chiếu**.

Các chỉ số đánh giá

- **ARI:** đo mức độ giống nhau giữa hai kết quả phân cụm trên cùng một tập khách hàng. Giá trị càng gần 1 thì hai kết quả càng tương đồng.
- **Init. ARI:** ARI trung bình trên $\binom{20}{2} = 190$ cặp kết quả từ 20 lần chạy K-Means với $n_init=1$. Mỗi mô hình được fit trên tập huấn luyện và gán nhãn cho cùng một tập đánh giá. Chỉ số này được dùng để kiểm tra liệu cấu trúc cụm có còn ổn định khi điều kiện khởi tạo yếu hay không.
- **Boot. ARI** $q_{0.05}$: phân vị 5% thực nghiệm của ARI qua 500 lần bootstrap tập huấn luyện. Trong mỗi lần, toàn bộ bước tiền xử lý và K-Means với $n_init = 10$ được fit lại, sau đó gán nhãn cho cùng một tập đánh giá và so sánh với mô hình tham chiếu.
- **Size** $q_{0.05}$: phân vị 5% thực nghiệm của tỷ lệ cluster nhỏ nhất trên tập đánh giá qua 500 lần bootstrap.
- **Max contr.:** tỷ lệ đóng góp lớn nhất của một đặc trưng vào tổng khoảng cách bình phương từ khách hàng đến centroid trên tập đánh giá. Giá trị cao cho thấy kết quả phân cụm bị chi phối bởi một đặc trưng.
- **Native Sil.:** Silhouette Score được tính trong không gian tiền xử lý riêng của từng cấu hình. Chỉ số này dùng để mô tả từng cấu hình và không được dùng để so sánh trực tiếp giữa các phương pháp tiền xử lý.
- **Common Sil.:** các nhãn cluster được đánh giá trong cùng không gian Log+Std, sử dụng bộ tiền xử lý chỉ được fit trên tập huấn luyện. Đây là chỉ số bổ sung để so sánh các cấu hình trong cùng một không gian tham chiếu.

- **Temporal ARI:** các cặp train-eval được dịch lần lượt -120 , -60 và 0 ngày so với hai cutoff chính. Tại mỗi thời điểm, bước tiền xử lý và K-Means được fit lại độc lập. ARI được tính trên những khách hàng cũ xuất hiện ở cả hai snapshot. Giá trị báo cáo là trung vị của ba cặp so sánh và chỉ được dùng để tham khảo độ ổn định theo thời gian.

Native Sil. và Common Sil. được ước lượng trên tối đa 1500 khách hàng thuộc tập đánh giá bằng nhãn của mô hình tham chiếu.

Trước khi xem kết quả, nhóm đặt ra bốn điều kiện kỹ thuật bắt buộc:

- Init. ARI ≥ 0.85 ;
- Boot. ARI $q_{0.05} \geq 0.85$;
- Size $q_{0.05} \geq 8\%$;
- Max contr. $\leq 80\%$.

Chi phí không thuộc các điều kiện kỹ thuật. Để hỗ trợ quyết định triển khai, công ty giả định mỗi cluster cần một chiến dịch riêng với chi phí cố định 30 triệu đồng và tổng ngân sách là 135 triệu đồng.

Kết quả được trình bày trong Bảng 12 và Bảng 13.

Bảng 12: Kết quả các điều kiện kỹ thuật và chi phí triển khai

Cấu hình	Tiền xử lý	K	Init. ARI	Boot. ARI $q_{0.05}$	Size $q_{0.05}$	Max contr.	Chi phí
R3	Raw	3	0.7838	0.4961	0.03%	99.45%	90 triệu
R4	Raw	4	0.7455	0.3182	0.02%	99.38%	120 triệu
R5	Raw	5	0.7397	0.3790	0.00%	99.09%	150 triệu
S3	Log+Std	3	0.9422	0.9581	20.11%	54.38%	90 triệu
S4	Log+Std	4	0.7368	0.5161	9.32%	69.59%	120 triệu
S5	Log+Std	5	0.8998	0.9157	7.84%	77.48%	150 triệu
W3	Win+Log+Rob	3	0.9859	0.9473	21.43%	59.29%	90 triệu
W4	Win+Log+Rob	4	0.7274	0.9538	16.31%	75.14%	120 triệu
W5	Win+Log+Rob	5	0.9741	0.8946	10.48%	81.41%	150 triệu

Bảng 13: Silhouette Score và độ ổn định theo thời gian

Cấu hình	Native Sil.	Common Sil.	Temporal ARI trung vị
R3	0.9627	0.3029	0.6585
R4	0.9373	0.2742	0.7557
R5	0.8791	0.1387	0.6847
S3	0.3829	0.3829	0.5771
S4	0.5139	0.5139	0.4144
S5	0.4822	0.4822	0.5450
W3	0.3577	0.3652	0.5791
W4	0.5186	0.5134	0.4423
W5	0.4645	0.4656	0.5406

Câu hỏi: Dựa trên bốn điều kiện kỹ thuật bắt buộc, những cấu hình nào đủ điều kiện để được xem xét ở bước tiếp theo?

- A. S3, S4 và W3.
- B. W3 và W4.
- C. S3 và W3.
- D. S3, S5 và W3.

Đáp án đúng: C.

Giải thích

- **Xét các điều kiện kỹ thuật**

Các cấu hình Raw đều không đạt yêu cầu. R3, R4 và R5 có Init. ARI và Boot. ARI $q_{0.05}$ thấp hơn 0.85, tạo ra các cluster rất nhỏ và gần như bị Monetary chi phối hoàn toàn.

S4 không đạt vì Init. ARI = 0.7368 < 0.85 và Boot. ARI $q_{0.05}$ = 0.5161 < 0.85.

W4 đạt yêu cầu về Boot. ARI, kích thước cluster và mức cân bằng đặc trưng, nhưng Init. ARI = 0.7274 < 0.85.

S5 có Size $q_{0.05}$ = 7.84% < 8%, trong khi W5 có Max contr. = 81.41% > 80%.

Sau khi đối chiếu bốn điều kiện kỹ thuật, chỉ còn S3 và W3.

- **Vì sao đáp án C đúng?**

S3 có Init. ARI = 0.9422, Boot. ARI $q_{0.05}$ = 0.9581, Size $q_{0.05}$ = 20.11% và Max contr. = 54.38%.

W3 có Init. ARI = 0.9859, Boot. ARI $q_{0.05}$ = 0.9473, Size $q_{0.05}$ = 21.43% và Max contr. = 59.29%.

Cả hai cấu hình đều đáp ứng đầy đủ bốn điều kiện kỹ thuật.

- **Vì sao A sai?**

A đưa S4 vào nhóm đạt yêu cầu, nhưng Init. ARI và Boot. ARI $q_{0.05}$ của S4 đều thấp hơn ngưỡng 0.85.

- **Vì sao B sai?**

B đưa W4 vào nhóm đạt yêu cầu, nhưng Init. ARI = 0.7274 < 0.85.

- **Vì sao D sai?**

D đưa S5 vào nhóm đạt yêu cầu, nhưng Size $q_{0.05}$ = 7.84% < 8%.

Câu hỏi: Công ty cần lựa chọn giữa các cấu hình đã vượt qua bước sàng lọc kỹ thuật. Thiết kế đánh giá nào phù hợp nhất để xác định cấu hình tạo ra giá trị kinh doanh cao hơn?

- A. Phân bổ ngẫu nhiên khách hàng vào từng chiến lược phân khúc, triển khai đồng thời với ngân sách tương đương, sau đó chọn chiến lược có tỷ lệ phản hồi cao nhất mà không sử dụng nhóm đối chứng.
- B. Lập hồ sơ các cluster, xác định các chiến dịch có thể triển khai, sau đó phân bổ ngẫu nhiên khách hàng vào từng chiến lược phân khúc và một nhóm đối chứng, rồi lựa chọn dựa trên uplift và lợi nhuận gia tăng sau chi phí.
- C. Phân bổ ngẫu nhiên khách hàng vào từng chiến lược phân khúc và một nhóm đối chứng, sau đó chọn chiến lược có tỷ lệ phản hồi cao nhất mà không xét giá trị đơn hàng, chi phí ưu đãi và chi phí triển khai.
- D. Triển khai các chiến lược phân khúc và nhóm đối chứng tại những khu vực khác nhau, lựa chọn khu vực dựa trên doanh thu lịch sử, sau đó so sánh uplift và lợi nhuận giữa các khu vực.

Đáp án đúng: B.

Giải thích

- **Vì sao đáp án B đúng?**

Câu hỏi yêu cầu xác định cấu hình tạo ra giá trị kinh doanh cao hơn. Vì vậy, thiết kế đánh giá phải cung cấp được kết quả phản thực, hạn chế yếu tố gây nhiễu và đo đúng đại lượng kinh doanh.

Nhóm đối chứng cho biết kết quả có thể xảy ra nếu không áp dụng chiến lược marketing. Phân bổ ngẫu nhiên giúp cân bằng các đặc điểm quan sát được và không quan sát được giữa các nhóm, nhờ đó chênh lệch kết quả có thể được quy cho chiến lược phân khúc.

Uplift đo phần cải thiện so với nhóm đối chứng, trong khi lợi nhuận gia tăng sau chi phí phản ánh giá trị kinh doanh thực tế sau khi tính đến doanh thu, ưu đãi và chi phí triển khai.

B là phương án duy nhất kết hợp đầy đủ việc lập hồ sơ cluster, phân bổ ngẫu nhiên, nhóm đối chứng và đại lượng đánh giá phù hợp.

- **Vì sao A sai?**

A có phân bổ ngẫu nhiên và triển khai đồng thời, nhưng không có nhóm đối chứng. Vì vậy, tỷ lệ phản hồi quan sát được bao gồm cả những khách hàng vốn có thể mua hàng ngay cả khi không nhận chiến dịch.

Thiết kế này có thể so sánh kết quả quan sát giữa các chiến lược, nhưng không xác định được mỗi chiến lược thực sự tạo thêm bao nhiêu phản hồi hoặc lợi nhuận so với trường hợp không can thiệp.

- **Vì sao C sai?**

C có phân bổ ngẫu nhiên và nhóm đối chứng, nhưng sử dụng tỷ lệ phản hồi làm tiêu chí quyết định duy nhất.

Một chiến lược có thể tạo ra nhiều phản hồi hơn nhưng cần ưu đãi lớn hơn, thu hút các đơn hàng có giá trị thấp hơn hoặc phát sinh chi phí triển khai cao hơn. Vì vậy, tỷ lệ phản hồi không đủ để đại diện cho giá trị kinh doanh.

- **Vì sao D sai?**

D có nhóm đối chứng và đo các kết quả kinh doanh phù hợp, nhưng chiến lược được gán theo khu vực dựa trên doanh thu lịch sử thay vì phân bổ ngẫu nhiên.

Các khu vực có thể khác nhau sẵn về hành vi khách hàng, mùa vụ, sức mua, mức độ cạnh tranh và hiệu quả vận hành. Vì vậy, chênh lệch kết quả có thể xuất phát từ những khác biệt ban đầu thay vì chiến lược phân khúc.

Tham chiếu: [Colab Notebook](#)

IX. AIO26M02Q10

Trong tháng 1/2026, doanh nghiệp muốn đánh giá hiệu quả bán hàng của từng kênh store và ecommerce. Với mỗi kênh bán hàng, cần tính các chỉ số sau:

- Tổng số đơn hàng.
- Tổng số khách hàng duy nhất đã đặt hàng.
- Tổng số sản phẩm đã bán.
- Tổng doanh thu, sử dụng cột `orders.order_total`.
- Giá trị đơn hàng trung bình:

$$\text{avg_order_value} = \frac{\text{Tổng doanh thu}}{\text{Tổng số đơn hàng}}$$

Biết rằng:

- Bảng `orders` có grain là 1 dòng trên 1 đơn hàng.
- Bảng `order_items` có grain là 1 dòng trên 1 sản phẩm trong đơn hàng.
- Một đơn hàng có thể chứa nhiều dòng sản phẩm.
- Chỉ lấy những đơn hàng có `order_date` thuộc tháng 1/2026.
- Kết quả chỉ giữ các kênh có ít nhất 100 đơn hàng.

Hoàn thành câu SQL sau sao cho các chỉ số không bị phóng đại do quan hệ 1 : N giữa `orders` và `order_items`:

SQL query: Tính hiệu quả bán hàng theo kênh

```

1 WITH item_summary AS (
2     SELECT
3         order_id,
4         _____(1) AS units_sold
5     FROM order_items
6     GROUP BY _____(2)
7 )
8
9 SELECT
10     o.channel,
11     _____(3)           AS total_orders,
12     _____(4)           AS unique_customers,
13     SUM(i.units_sold)       AS total_units_sold,
14     _____(5)           AS total_revenue,
15     _____(6)           AS avg_order_value
16 FROM orders o
17 LEFT JOIN item_summary i
18 ON _____(7)
19 WHERE o.order_date >= '2026-01-01'
20     AND o.order_date < '2026-02-01'
21 GROUP BY _____(8)
22 HAVING _____(9)
23 ORDER BY total_revenue DESC;

```

A.

- (1) COUNT(quantity)
- (2) product_id
- (3) COUNT(DISTINCT o.order_id)
- (4) COUNT(o.customer_id)
- (5) SUM(DISTINCT o.order_total)
- (6) SUM(o.order_total) / COUNT(i.order_id)
- (7) o.customer_id = i.order_id
- (8) o.channel
- (9) SUM(i.units_sold) >= 100

B.

- (1) SUM(quantity)
- (2) order_id
- (3) COUNT(o.order_id)
- (4) COUNT(DISTINCT o.customer_id)
- (5) SUM(o.order_total)
- (6) AVG(o.order_total)
- (7) o.order_id = i.order_id
- (8) o.channel
- (9) COUNT(o.order_id) >= 100

C.

- (1) SUM(quantity)
- (2) order_id
- (3) COUNT(i.order_id)
- (4) COUNT(DISTINCT o.customer_id)
- (5) SUM(o.order_total)
- (6) SUM(o.order_total) / SUM(i.units_sold)
- (7) o.order_id = i.order_id
- (8) o.channel, o.order_id
- (9) COUNT(i.order_id) >= 100

D.

- (1) SUM(quantity * unit_price)
- (2) order_id
- (3) COUNT(DISTINCT o.customer_id)
- (4) COUNT(DISTINCT o.order_id)
- (5) SUM(i.units_sold)
- (6) AVG(i.units_sold)
- (7) o.order_id = i.order_id
- (8) o.channel
- (9) COUNT(DISTINCT o.customer_id) >= 100

Đáp án

Đáp án: B

Giải thích:

Bảng **orders** có **grain** là 1 dòng trên 1 đơn hàng, trong khi bảng **order_items** có **grain** là 1 dòng trên 1 sản phẩm trong đơn hàng. Quan hệ giữa hai bảng là quan hệ 1 : N, nghĩa là một đơn hàng có thể chứa nhiều dòng sản phẩm.

Nếu JOIN trực tiếp hai bảng rồi tính:

SUM(o.order_total)

thì mỗi đơn hàng sẽ bị lặp lại theo số dòng sản phẩm. Ví dụ, một đơn hàng trị giá 500 gồm 3 dòng sản phẩm sẽ xuất hiện 3 lần sau phép JOIN và đóng góp thành 1500 vào tổng doanh thu. Đây là lỗi rất phổ biến khi thực hiện phép JOIN giữa các bảng có grain khác nhau.

Để tránh hiện tượng này, trước tiên cần tổng hợp bảng **order_items** theo **order_id**, đưa dữ liệu về đúng grain là 1 dòng trên 1 đơn hàng. Khi đó, mỗi đơn hàng chỉ còn một dòng chứa tổng số lượng sản phẩm (**units_sold**). Sau khi JOIN với bảng **orders**, mỗi đơn hàng vẫn chỉ xuất hiện một lần nên:

- COUNT(o.order_id) tính đúng số đơn hàng.
- COUNT(DISTINCT o.customer_id) tính đúng số khách hàng duy nhất.
- SUM(i.units_sold) tính đúng tổng số sản phẩm đã bán.

- `SUM(o.order_total)` không bị nhân lên do phép JOIN.
- `AVG(o.order_total)` phản ánh đúng giá trị trung bình của một đơn hàng.

Ngoài ra, điều kiện:

`HAVING COUNT(o.order_id) >= 100`

được đặt trong mệnh đề `HAVING` vì đây là điều kiện lọc sau khi đã `GROUP BY`. Nếu đặt trong `WHERE`, SQL sẽ báo lỗi do `COUNT()` là hàm tổng hợp và chỉ được tính sau bước gom nhóm.

Phương án A không đúng vì `COUNT(quantity)` chỉ đếm số dòng sản phẩm thay vì tổng số lượng bán, `GROUP BY product_id` làm sai grain của dữ liệu, và `SUM(DISTINCT order_total)` có thể làm mất doanh thu khi nhiều đơn hàng khác nhau có cùng giá trị.

Phương án C không đúng vì `GROUP BY o.channel, o.order_id` khiến kết quả còn ở grain từng đơn hàng thay vì từng kênh bán hàng, đồng thời `SUM(order_total) / SUM(units_sold)` là doanh thu trên mỗi sản phẩm chứ không phải giá trị trung bình của một đơn hàng.


Phương án D không đúng vì `SUM(quantity * unit_price)` không sử dụng cột doanh thu của đơn hàng, `COUNT(DISTINCT customer_id)` không phải số đơn hàng, và `AVG(i.units_sold)` chỉ tính số lượng sản phẩm trung bình trên mỗi đơn.

Vì vậy, phương án B là phương án duy nhất xử lý đúng grain của dữ liệu, tránh hiện tượng nhân bản doanh thu sau phép JOIN và tính chính xác tất cả các chỉ số theo từng kênh bán hàng.

X. AIO26M02Q11

Bảng `campaigns` chứa dữ liệu chiến dịch marketing của nhiều thương hiệu, mỗi dòng là một campaign được định danh bằng `Campaign_ID`. Dữ liệu thô có lỗi, nên nhóm phân tích xây một quy trình làm sạch gồm **6 bước**, chạy theo đúng thứ tự sau:

Quy trình 6 bước làm sạch dữ liệu



Hình 5: Data Cleaning Pipeline: 6 bước clean data.

Trong đó, mô hình phễu là quy tắc mô tả thứ tự bắt buộc của hành vi người dùng. Một quảng cáo phải được hiển thị thì mới có người click, phải có người click thì mới có lead, và phải có lead thì mới có đơn hàng. Tức là mọi dòng hợp lệ phải thỏa:

$$\text{Impressions} \geq \text{Clicks} \geq \text{Leads} \geq \text{Conversions}$$

Bước 4 xóa mọi dòng vi phạm quy tắc này:

```

1 DELETE FROM campaigns
2 WHERE Clicks > Impressions OR Leads > Clicks OR Conversions > Leads;

```

Một bạn trong nhóm lập luận: Các bước 2–6 đều là `DELETE` với điều kiện độc lập nhau, nên chạy thứ tự nào cũng cho kết quả như nhau. Do đó bạn đó giữ nguyên bước 3 ở vị trí trước bước 4, và vẫn chạy đầy đủ cả 6 bước.

Trong bảng có 2 dòng cùng mang `Campaign_ID = NY-CMP-10123`:

Bản	Impressions	Clicks	Leads	Conversions	Revenue	Acq_Cost
A	50.000	4.000	1.600	800	900.000	100,00
B	3.000	5.200	1.900	950	880.000	100,00

Bước 3 được thực hiện bằng câu lệnh sau:


```

1 CREATE TABLE campaigns_clean AS
2 SELECT * FROM campaigns
3 GROUP BY Campaign_ID;
4
5 DROP TABLE campaigns;
6 RENAME TABLE campaigns_clean TO campaigns;

```

(Giả sử sql_mode đã tắt ONLY_FULL_GROUP_BY nên câu lệnh trên chạy được, không báo lỗi.)

Campaign_ID = NY-CMP-10123 đi qua quy trình cleaning



Lưu ý: thứ tự trên đặt bước khử trùng lặp TRƯỚC bước lọc lỗi funnel.

Hình 6: Bảng Campaign đi qua quy trình clean data.

Hỏi: Hệ quả nghiêm trọng nhất của việc đặt bước khử trùng lặp **trước** bước lọc lỗi funnel là gì?

- A. Không có hệ quả nào, vì các điều kiện DELETE độc lập nên đổi thứ tự vẫn cho ra cùng một tập dữ liệu cuối cùng
- B. Bản B chắc chắn được giữ lại đến cuối quy trình, làm tỷ lệ click của campaign vượt quá 100% và sai lệch chỉ số tổng hợp
- C. Không có hệ quả nào, vì MySQL luôn giữ dòng được ghi vào trước, tức bản A, nên bản sạch chắc chắn được giữ lại
- D. GROUP BY không đảm bảo giữ bản nào; nếu bản B được giữ thì bước 4 xóa nốt, khiến campaign biến mất khỏi dữ liệu

💡 Đáp án

Đáp án: D

Giải thích

Hai bản ghi có cùng Campaign_ID = NY-CMP-10123:

- **Bản A** hợp lệ vì

$$50.000 \geq 4.000 \geq 1.600 \geq 800.$$

- **Bản B** vi phạm logic funnel vì

$$\text{Clicks} = 5.200 > \text{Impressions} = 3.000.$$

Tại bước 3, hai bản ghi được khử trùng lặp bằng câu lệnh:

```
1 SELECT *
2 FROM campaigns
3 GROUP BY Campaign_ID;
```

Do ONLY_FULL_GROUP_BY đang tắt, câu lệnh trên vẫn chạy nhưng không bảo đảm bản A hay bản B được giữ. Nếu MySQL chọn bản B, bản A hợp lệ sẽ bị loại ở bước 3. Sau đó, bước 4 tiếp tục xóa bản B vì bản này vi phạm logic funnel.

💡 Chuỗi dẫn đến mất dữ liệu

A hợp lệ + B vi phạm $\xrightarrow{\text{Bước 3 giữ B}}$ chỉ còn B $\xrightarrow{\text{Bước 4 xóa B}}$ $\emptyset$

Vì vậy, campaign NY-CMP-10123 có thể biến mất hoàn toàn, mặc dù ban đầu có một bản ghi hợp lệ. Đây là hiện tượng **mất dữ liệu âm thầm** (*silent data loss*).

💡 ONLY_FULL_GROUP_BY

Nếu ONLY_FULL_GROUP_BY được bật, MySQL sẽ từ chối câu lệnh `SELECT * ... GROUP BY Campaign_ID`. Khi đó, pipeline dừng tại bước 3 thay vì âm thầm chọn một bản ghi không xác định.

 Phân tích từng đáp án

- (a) SAI.
Bước 3 là phép chọn một bản ghi đại diện, không phải phép lọc độc lập trên từng dòng. Vì vậy, đổi thứ tự các bước có thể làm thay đổi kết quả.
- (b) SAI.
Bản B không chắc chắn được giữ. Nếu được giữ, nó cũng sẽ bị xóa ở bước 4 do vi phạm logic funnel.
- (c) SAI.
MySQL không bảo đảm luôn giữ bản ghi được chèn trước.
- (d) ĐÚNG.
Nếu bước 3 giữ bản B và loại bản A, bước 4 sẽ xóa tiếp bản B, khiến toàn bộ campaign biến mất.

Cách làm đúng

Cách 1 (điều chỉnh thứ tự xử lý): Thực hiện tất cả các phép lọc lỗi trên từng dòng, gồm các bước 2, 4, 5 và 6, trước khi khử trùng lặp.

Trong ví dụ này, bước kiểm tra logic funnel sẽ xóa bản B trước. Khi thực hiện khử trùng lặp, campaign NY-CMP-10123 chỉ còn bản A hợp lệ nên không còn nguy cơ chọn nhầm bản B.

```
1 -- Xoa cac dong co metric NULL
2 DELETE FROM campaigns
3 WHERE Impressions IS NULL
4     OR Clicks IS NULL
5     OR Leads IS NULL
6     OR Conversions IS NULL;
7
8 -- Xoa cac dong vi pham logic funnel
9 DELETE FROM campaigns
10 WHERE Clicks > Impressions
11     OR Leads > Clicks
12     OR Conversions > Leads;
13
14 -- Xoa cac dong co gia tri am
15 DELETE FROM campaigns
16 WHERE Impressions < 0
17     OR Clicks < 0
18     OR Leads < 0
19     OR Conversions < 0
20     OR Revenue < 0
21     OR Acq_Cost < 0;
```

Tuy nhiên, nếu một campaign vẫn còn nhiều bản ghi hợp lệ thì cần quy định rõ tiêu chí chọn bản ghi được giữ. Không nên tiếp tục sử dụng `SELECT * FROM campaigns GROUP BY Campaign_ID` để khử trùng lặp.

Cách 2 (chỉ định rõ bản ghi được giữ): Sử dụng hàm của số ROW_NUMBER() để xếp hạng các bản ghi trong mỗi campaign.

Ví dụ dưới đây giả sử bảng có cột row_id là khóa duy nhất của mỗi dòng. Trong mỗi campaign, truy vấn ưu tiên bản ghi có doanh thu lớn hơn; nếu doanh thu bằng nhau thì sử dụng row_id để xác định duy nhất bản ghi được giữ.

```
1 WITH ranked AS (  
2     SELECT c.*,  
3           ROW_NUMBER() OVER (  
4               PARTITION BY Campaign_ID  
5               ORDER BY Revenue DESC, row_id ASC  
6           ) AS rn  
7     FROM campaigns AS c  
8 )  
9 SELECT *  
10 FROM ranked  
11 WHERE rn = 1;
```

Nếu muốn tạo lại bảng đã khử trùng lặp, có thể thực hiện như sau. Danh sách cột trong câu lệnh SELECT cần được bổ sung đầy đủ theo cấu trúc thực tế của bảng campaigns.

```
1 CREATE TABLE campaigns_clean AS  
2 SELECT row_id,  
3        Campaign_ID,  
4        Impressions,  
5        Clicks,  
6        Leads,  
7        Conversions,  
8        Revenue,  
9        Acq_Cost  
10 FROM (  
11     SELECT c.*,  
12           ROW_NUMBER() OVER (  
13               PARTITION BY Campaign_ID  
14               ORDER BY Revenue DESC, row_id ASC  
15           ) AS rn  
16     FROM campaigns AS c  
17 ) AS ranked  
18 WHERE rn = 1;  
19  
20 DROP TABLE campaigns;  
21 RENAME TABLE campaigns_clean TO campaigns;
```

Nếu bảng chưa có khóa duy nhất như row_id, nên bổ sung khóa này trước khi khử trùng lặp. Một tiêu chí sắp xếp không đầy đủ vẫn có thể tạo ra kết quả không xác định khi nhiều bản ghi có cùng mức ưu tiên.

 Nguyên tắc thứ tự trong cleaning pipeline

Trong một cleaning pipeline, cần phân biệt hai loại thao tác:

- **Phép lọc theo dòng**, chẳng hạn `DELETE WHERE` với điều kiện được kiểm tra độc lập trên từng dòng.
- **Phép chọn bản ghi đại diện**, chẳng hạn khử trùng lặp, `GROUP BY` hoặc `ROW_NUMBER()`, quyết định bản ghi nào được giữ trong một nhóm.

Các phép lọc chỉ có thể đổi thứ tự an toàn khi điều kiện của chúng độc lập và không làm thay đổi cách đánh giá của nhau. Phép chọn bản ghi đại diện không nên được đổi thứ tự tùy tiện với các phép lọc. Cần thực hiện lọc dữ liệu lỗi trước hoặc chỉ định một tiêu chí lựa chọn đầy đủ, rõ ràng và xác định.

Việc tắt `ONLY_FULL_GROUP_BY` không phải là nguyên nhân gốc duy nhất, nhưng nó cho phép một truy vấn `GROUP BY` mơ hồ tiếp tục chạy và có thể gây mất dữ liệu âm thầm. Khi chế độ này được bật, MySQL sẽ phát hiện và chặn truy vấn, nhưng người lập trình vẫn phải viết lại logic khử trùng lặp cho đúng.